ASIGNATURA:
APLICACIONES DE MACHINE LEARNING

SISTEMAS INTELIGENTES



3. Aplicaciones de ML en Agrupación

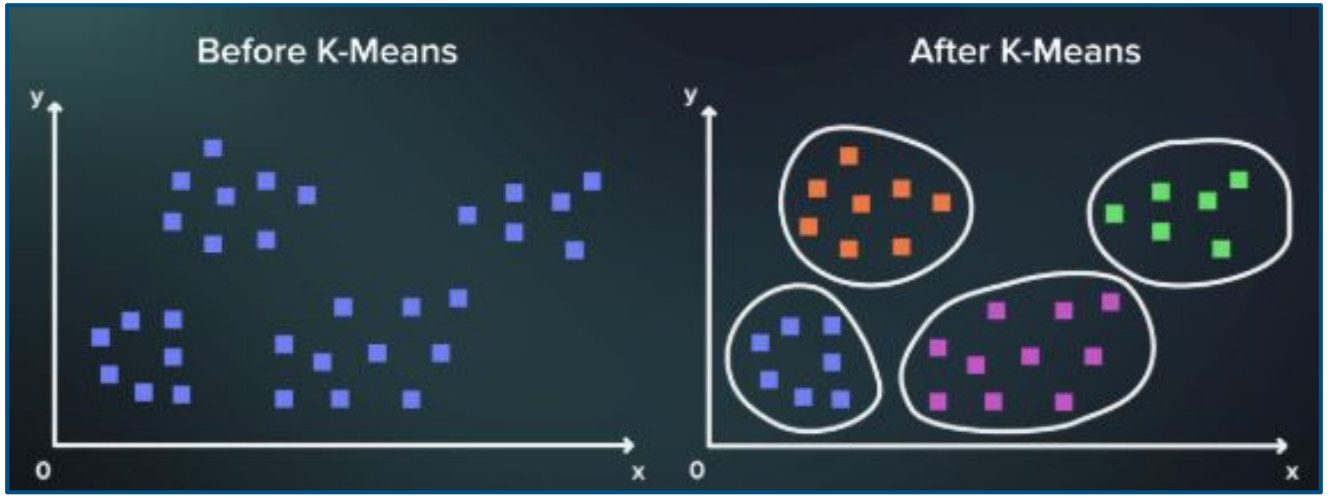
3.1 Revisión de modelos

3.2 Modelos Gaussianos Mixtos

Clustering: K-means

Agrupación

La agrupación K-means es un algoritmo popular de aprendizaje automático no supervisado que **se utiliza para dividir un conjunto de datos en un número predeterminado de subgrupos distintos** y no superpuestos (clústeres), los puntos de datos dentro del mismo clúster son similares entre sí.



Cómo funciona K-means

Paso 1 — Elegir K
Número de clusters que queremos formar (por ejemplo, K=3).

Paso 2 — Inicializar centroides
Selecciona aleatoriamente K puntos como centroides iniciales.

Paso 3 — Asignación
Cada punto se asigna al cluster con el centroide **más cercano** (normalmente usando **distancia euclidiana**).

Paso 4 — Actualización
Se recalcula el centroide como el **promedio** de todos los puntos en ese cluster.

Se repite 3y4 hasta que los centroides dejan de moverse.

¿Qué optimiza K-Means?
Minimiza:

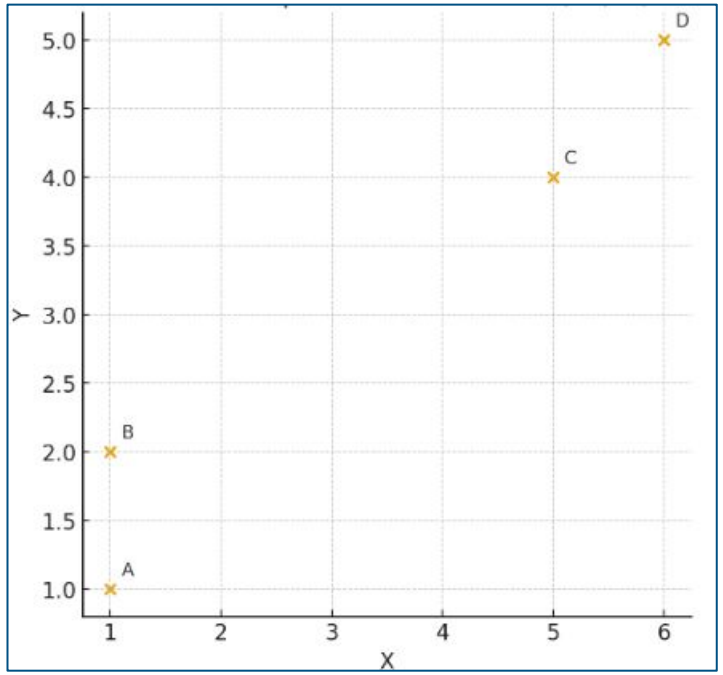
$$\sum_{k=1}^{K} \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

Es decir:
- Que los puntos estén **lo más cerca posible de su centroide**
- Que los clusters estén bien **compactos y definidos**

Ejemplo

Supongamos que tenemos este pequeño dataset (4 puntos en 2D):

Punto	x	y
A	1	1
B	1	2
C	5	4
D	6	5



1. Agrupar en **K = 2 clusters**.

2. Inicio centroides. Se elige al azar 2 puntos del dataset como centroides:
    1. Centroide 1 = **Punto A** = (1,1)
    2. Centroide 2 = **Punto C** = (5,4)

3. Asignar cada punto restante al centroide más cercano:
    1. d= sqrt[(x1−x2)^2 + (y1−y2)^2]

Punto B (1,2)

- Distancia a C1 = $\sqrt{((1-1)^2+(2-1)^2)}=\sqrt{1}=$ **1**
- Distancia a C2 = $\sqrt{((1-5)^2+(2-4)^2)}=\sqrt{(16+4)}=\sqrt{20}\approx$ **4.47**

→ B pertenece al cluster de C1.

Punto D (6,5)

- Distancia a C1 = $\sqrt{((6-1)^2+(5-1)^2)}=\sqrt{(25+16)}=\sqrt{41}\approx$ **6.4**
- Distancia a C2 = $\sqrt{((6-5)^2+(5-4)^2)}=\sqrt{2}\approx$ **1.4**

→ D pertenece al cluster de C2.

4. Actualizar centroide:

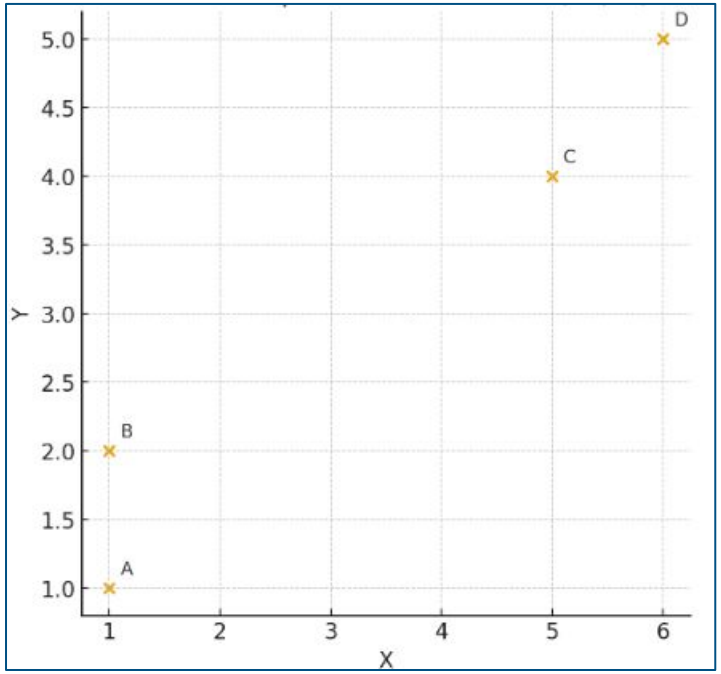
Se calculan los **nuevos centroides** como el **promedio de los puntos del cluster**.

Nuevo centroide del Cluster 1 (A y B)

$$C1 = \left(\frac{1+1}{2}, \frac{1+2}{2}\right) = (1\,, 1.5)$$

Nuevo centroide del Cluster 2 (C y D)

$$C2 = \left(\frac{5+6}{2}, \frac{4+5}{2}\right) = (5.5\,, 4.5)$$



Repetir pasos 3y4:

Considerando los **nuevos centroides**.

Punto	x	y
A	1	1
B	1	2
C	5	4
D	6	5

$$C1 = \left(\frac{1+1}{2}, \frac{1+2}{2}\right) = (1\,,1.5)$$

$$C2 = \left(\frac{5+6}{2}, \frac{4+5}{2}\right) = (5.5\,,4.5)$$

Punto A (1,1)

Distancia a C1:

$$\sqrt{(1-1)^2 + (1-1.5)^2} = \sqrt{0+0.25} = 0.5$$

Distancia a C2:

$$\sqrt{(1-5.5)^2 + (1-4.5)^2} = \sqrt{20.25+12.25} = \sqrt{32.5} \approx 5.7$$

A sigue en Cluster 1.

Punto B (1,2)

Distancia a C1:

$$\sqrt{(1-1)^2 + (2-1.5)^2} = 0.5$$

Distancia a C2:

$$\sqrt{(1-5.5)^2 + (2-4.5)^2} = \sqrt{20.25+6.25} = \sqrt{26.5} \approx 5.15$$

B sigue en Cluster 1.

Punto C (5,4)

Distancia a C1:

$$\sqrt{(5-1)^2 + (4-1.5)^2} = \approx 4.72$$

Distancia a C2:

$$\sqrt{(5-5.5)^2 + (4-4.5)^2} \approx 0.71$$

C sigue en Cluster 2.

Punto D (6,5)

Distancia a C1:

$$\sqrt{(6-1)^2 + (5-1.5)^2} \approx 6.10$$

Distancia a C2:

$$\sqrt{(6-5.5)^2 + (5-4.5)^2} \approx 0.71$$

D sigue en Cluster 2.

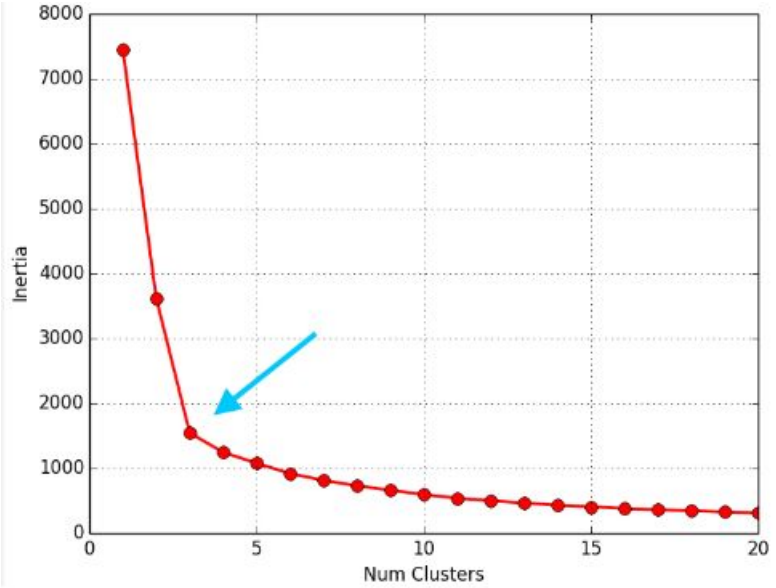
Que K usar?

1. Sentido del Negocio
Segmentación de clientes, marketing, perfiles.
Ejemplo: Se requiere segmentar clientes en 3 grupos: alto, medio, bajo.

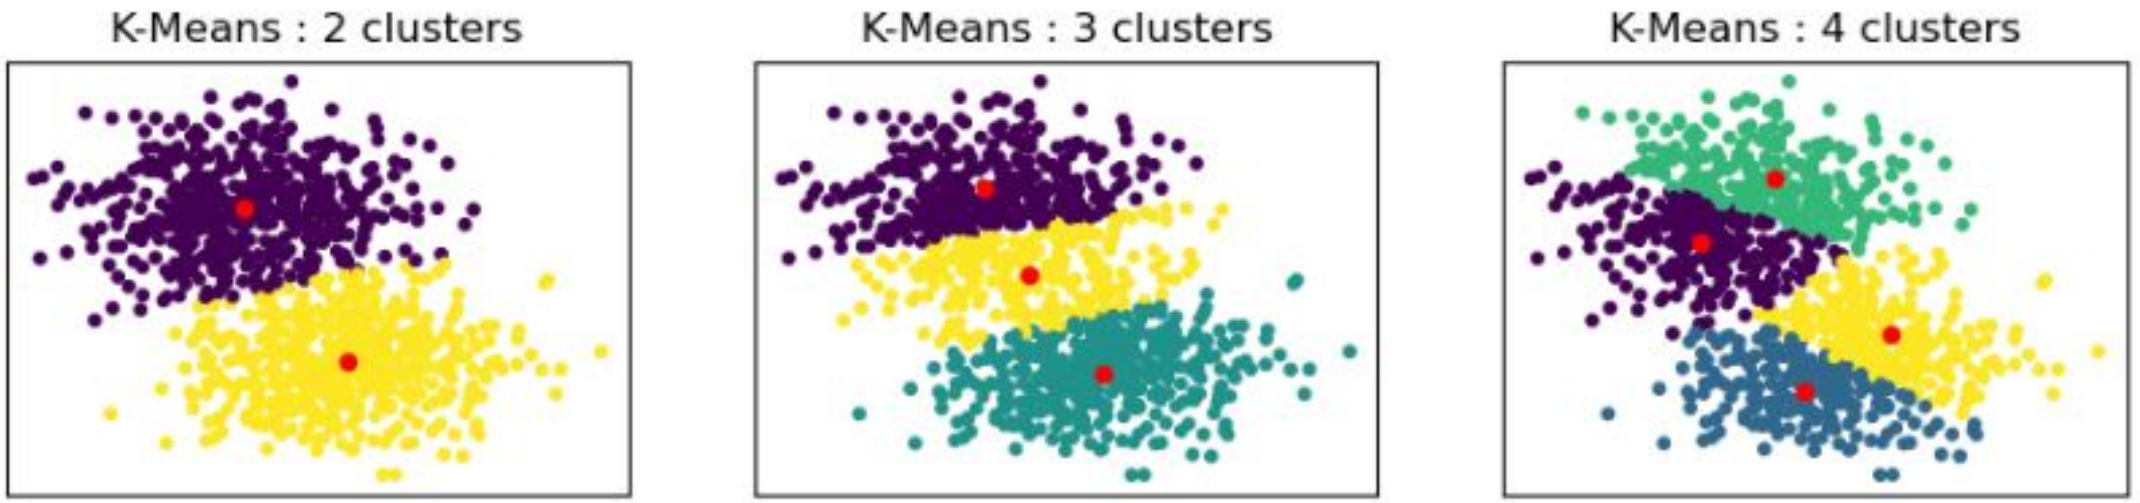
2. Método del Codo
Este método mide la **inercia**, que es la suma de distancias de cada punto a su centroide.

$$\sum_{k=1}^{K} \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

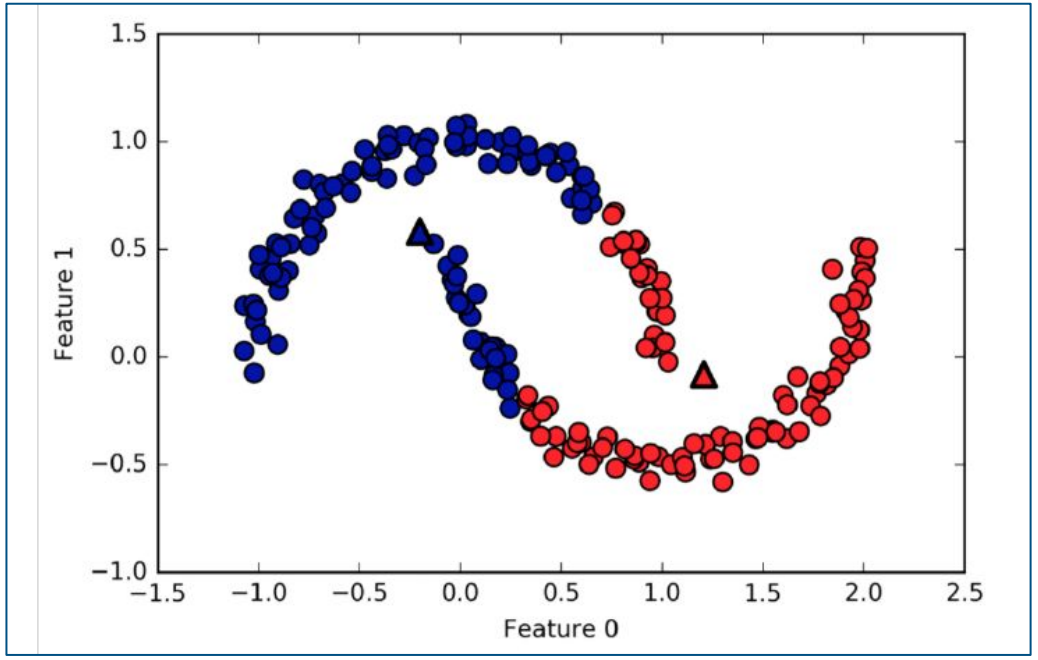
El punto donde la curva deja de bajar abruptamente (forma de codo) ⟶ allí está el K óptimo

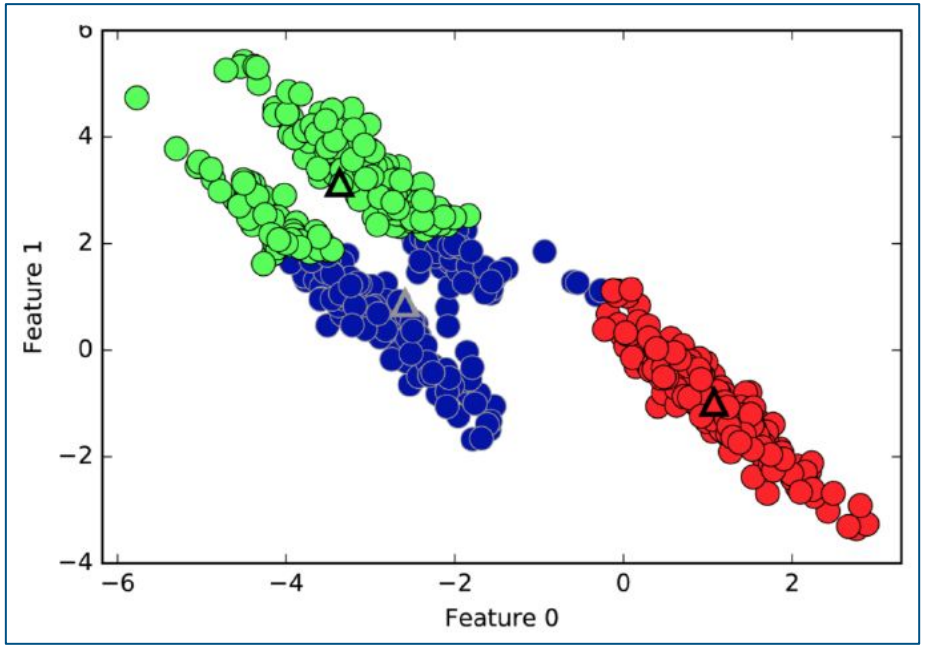


Muy útil cuando quieres interpretar centroides como “perfiles” de clientes.



- **Limitaciones**
  - ✗ Necesita elegir K antes de entrenar
  - ✗ No funciona bien con **clusters no esféricos**
  - ✗ Sensible a *outliers*



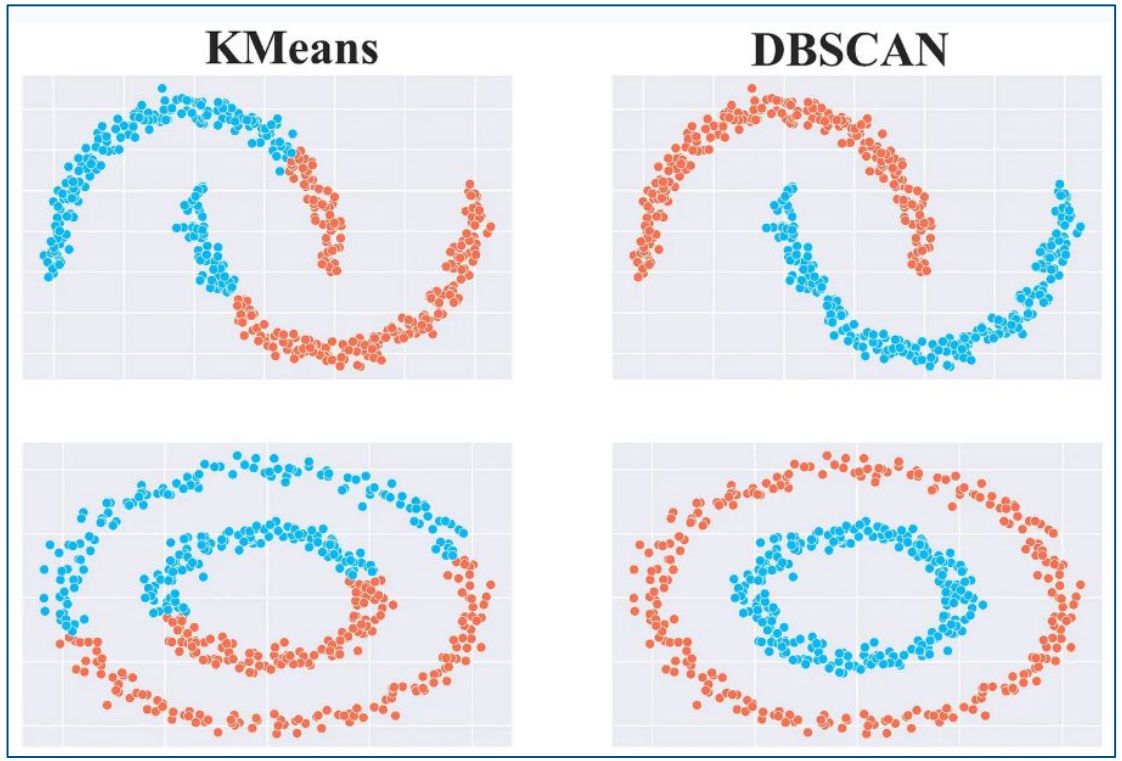


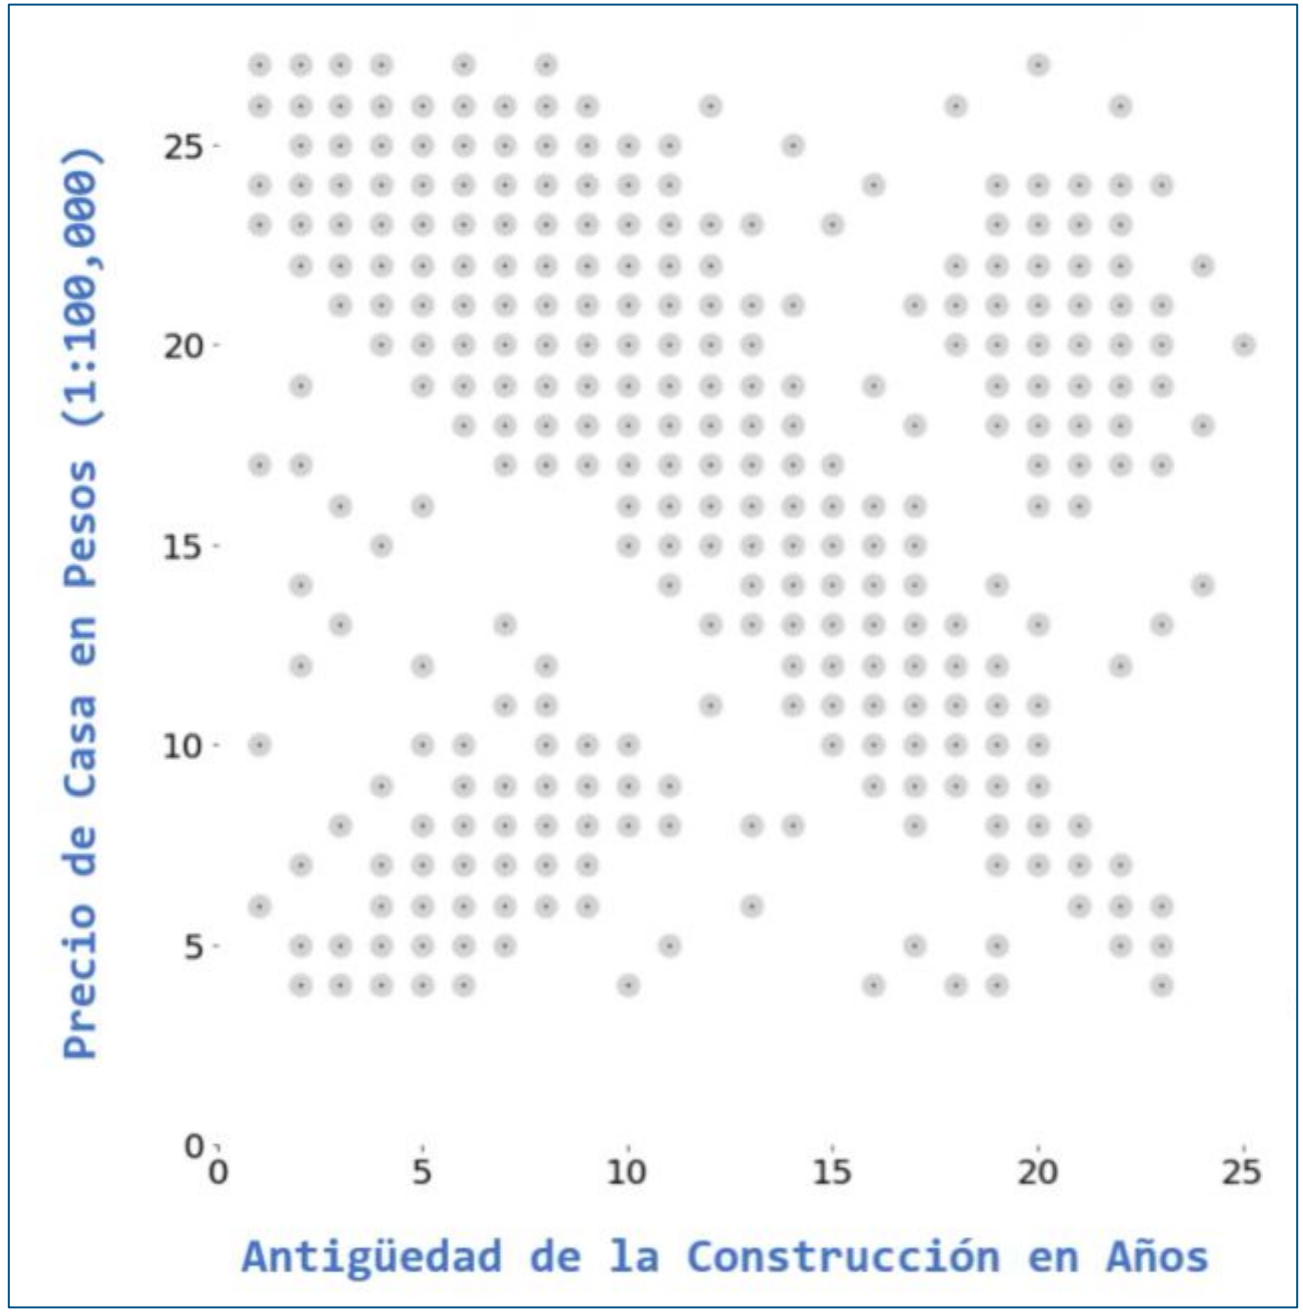
Density-Based Spatial Clustering of Applications with Noise (DBSCAN)

Agrupamiento espacial basado en densidad de aplicaciones con ruido (DBSCAN)

DBSCAN es un algoritmo de agrupamiento basado en densidad que agrupa puntos cercanos en un conjunto de datos. Encuentra grupos de formas arbitrarias y es robusto al ruido, a diferencia de K-Means.

El algoritmo utiliza dos parámetros clave:
epsilon (el radio de la vecindad).
min_samples (el número de muestras en dentro del radio para que un punto se considere un punto core/central).



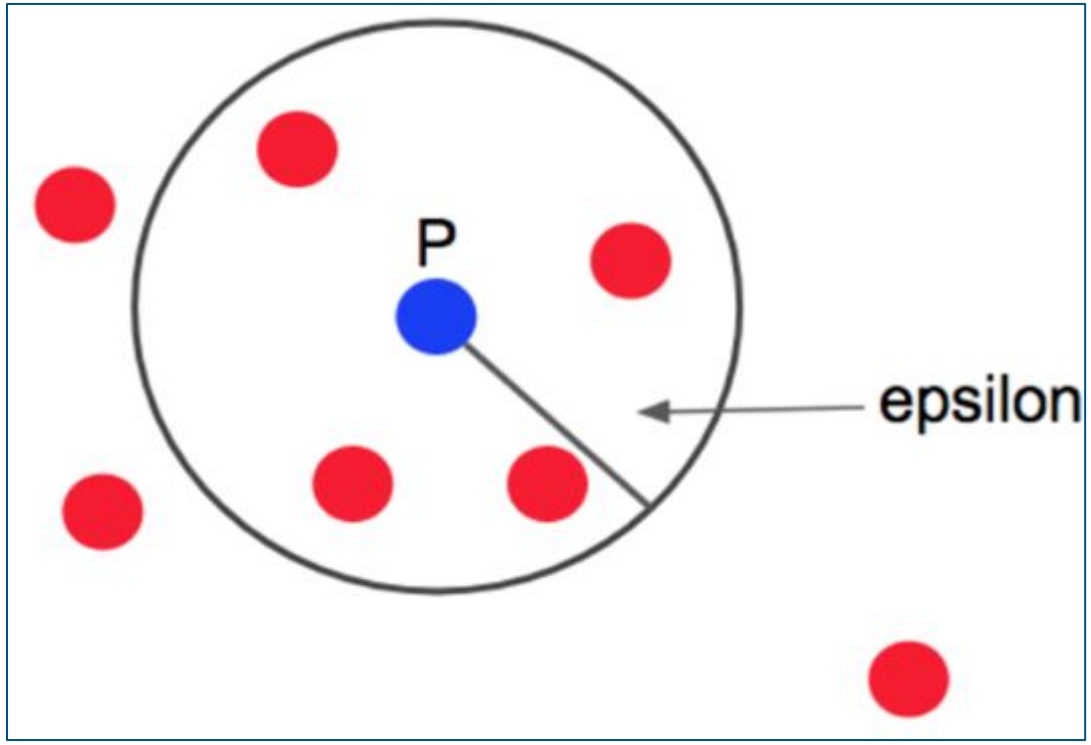

Precio de Casa en Pesos (1:100,000)
25
20
15
10
5
0
0
5
10
15
20
25
Antigüedad de la Construcción en Años

Epsilon (ε)

ε es el radio del vecindario.
Define **qué tan cerca** deben estar dos puntos para considerarse **vecinos**.

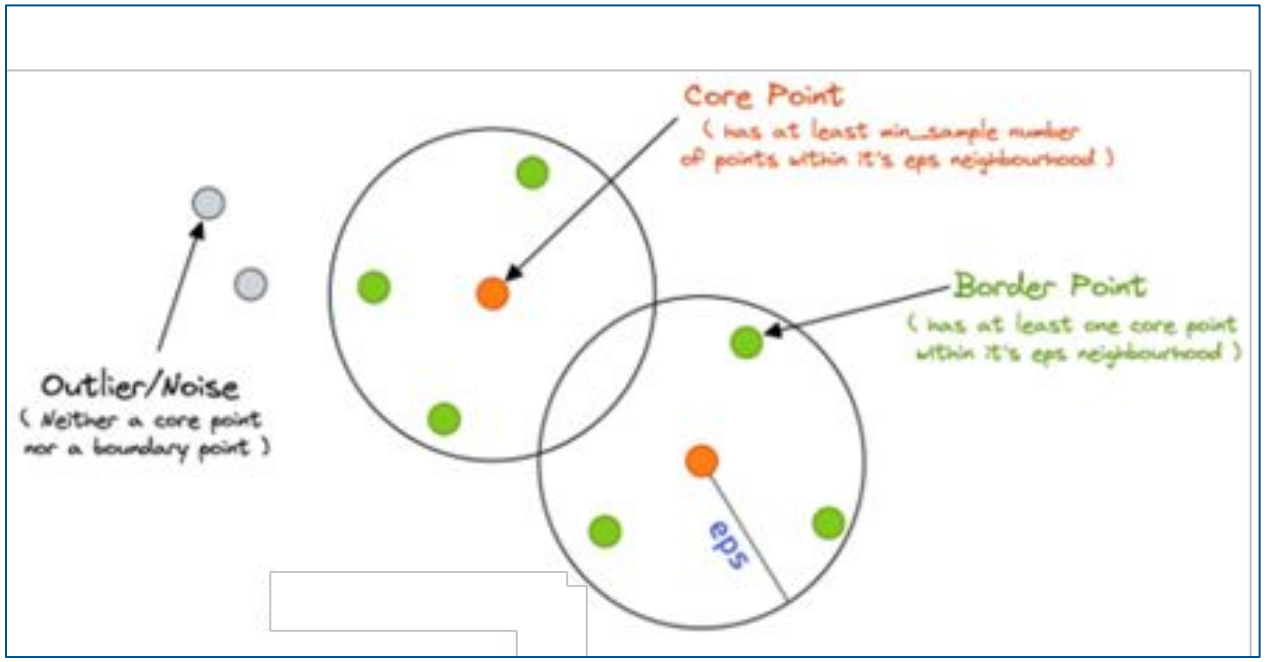
DBSCAN forma clusters basados en **densidad**.
Un punto será parte de un cluster si:
está rodeado de suficientes vecinos (≥ MinPts) dentro de una distancia **ε.**

ε muy pequeño ⟶ DBSCAN no encuentra vecinos
ε muy grande ⟶ DBSCAN une todo en un solo cluster gigante

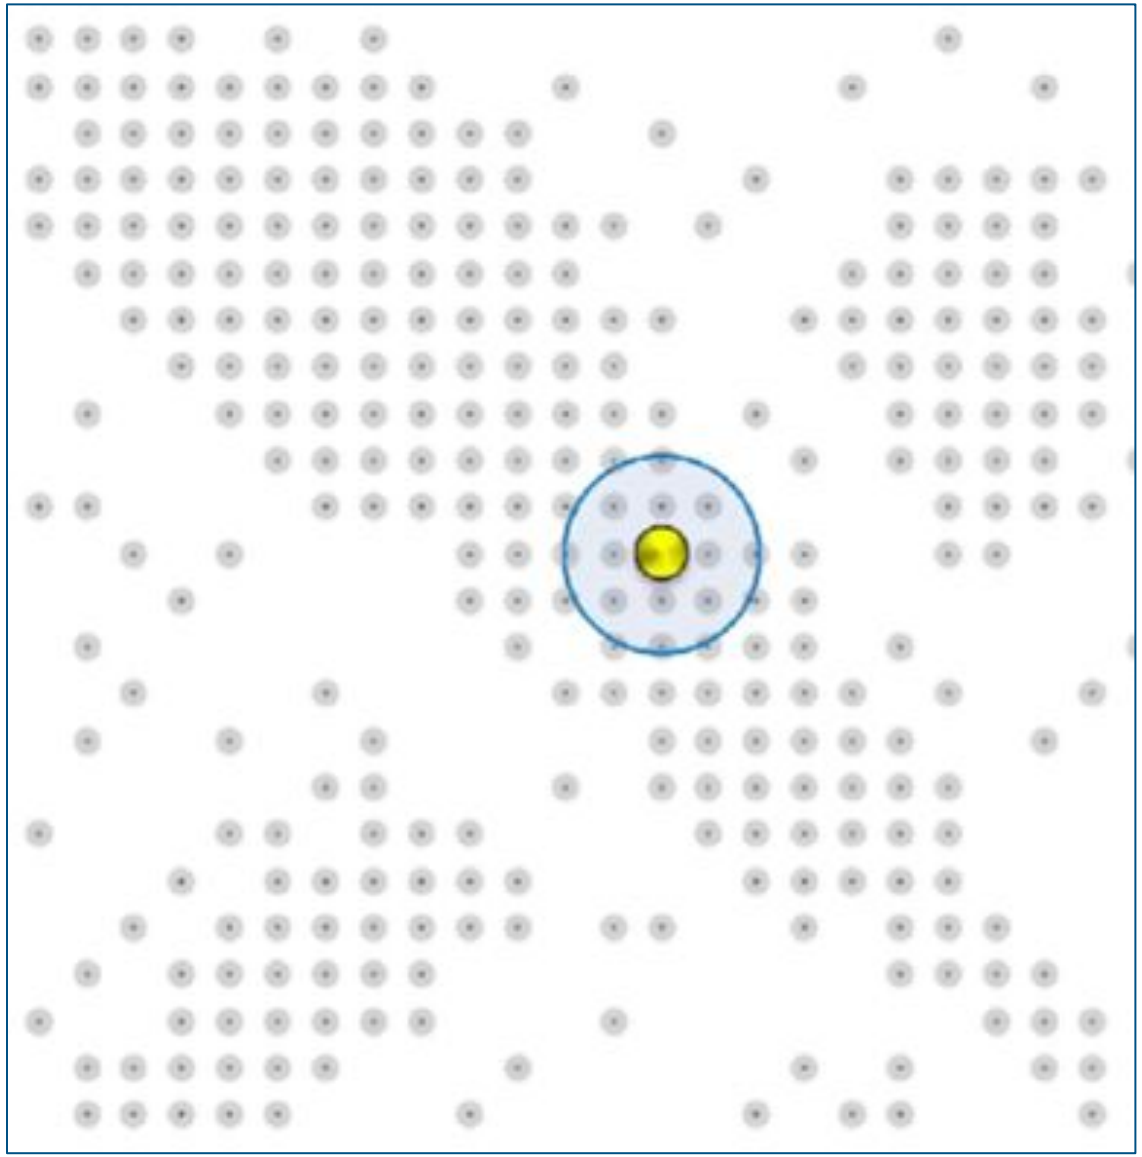


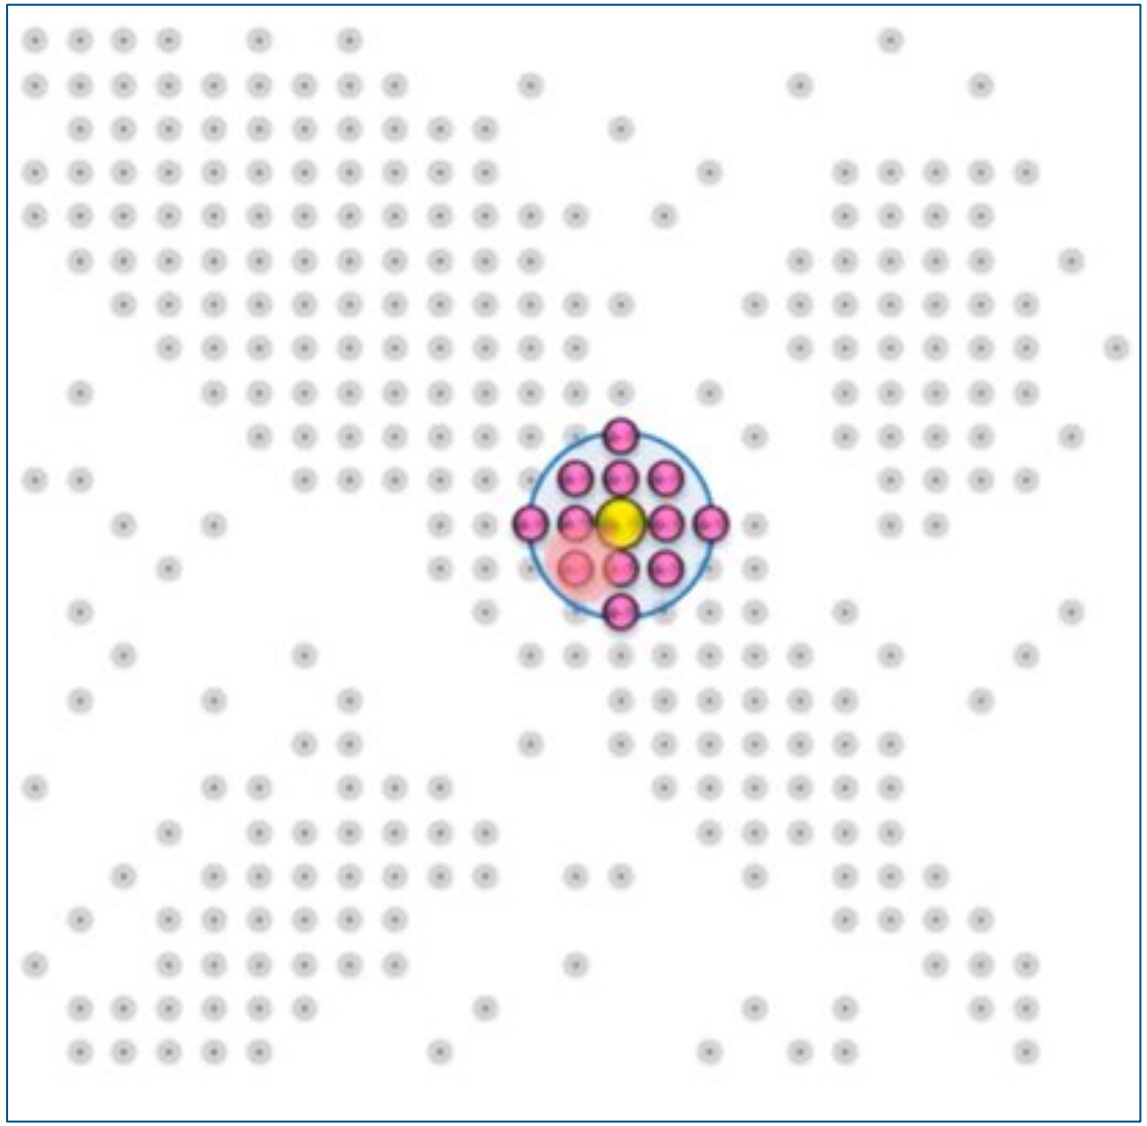
✔ **Si dentro del círculo hay suficientes puntos (MinPts)**
→ eres un **core point**
→ se forma un cluster
✔ **Si hay pocos puntos dentro del círculo**
→ eres **border point** o **ruido**

MinPts es el número mínimo de puntos que deben existir dentro del radio ε para que un punto sea considerado un punto núcleo (core point).

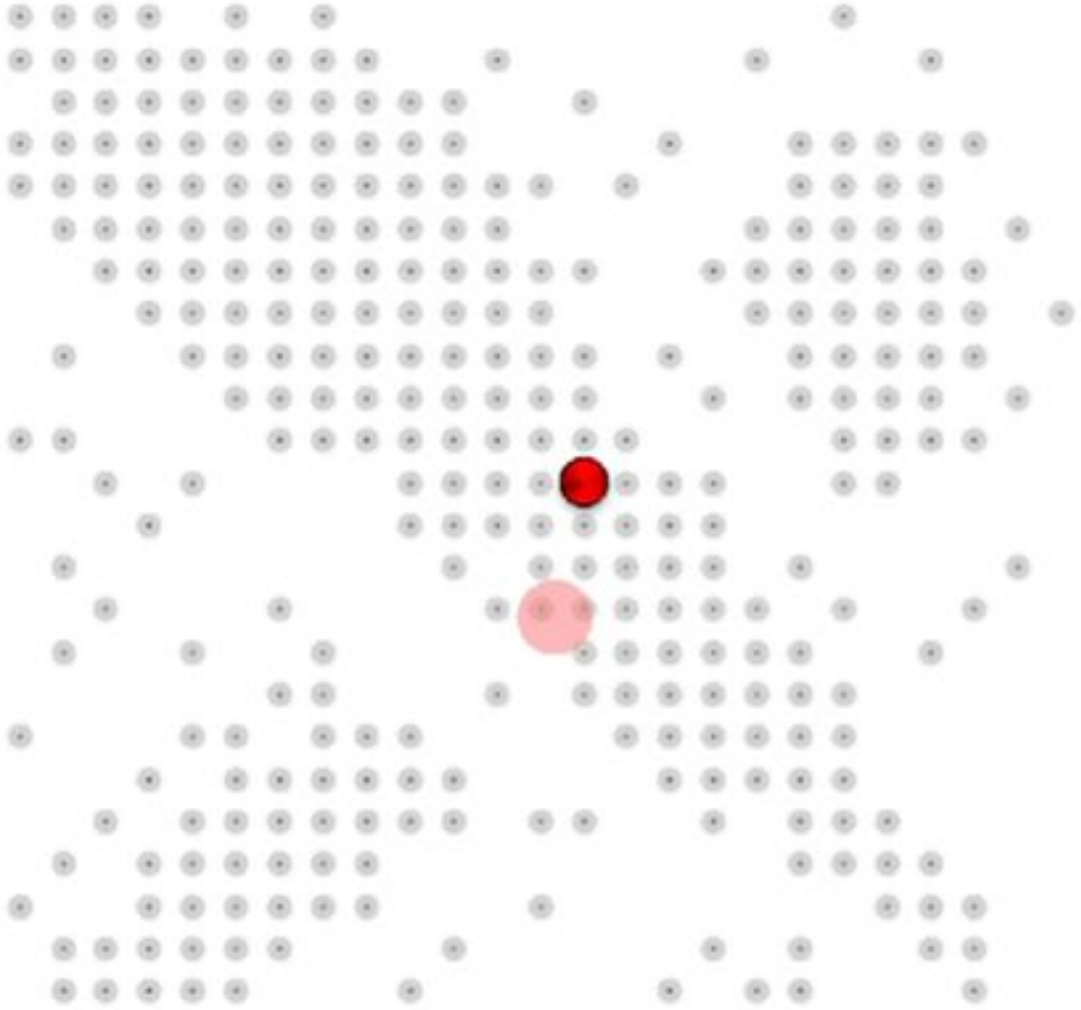


- Si un punto tiene ≥ MinPts dentro del círculo de radio ε → Core Point
- Si tiene menos pero está cerca de un Core → Border Point
- Si no cumple nada → Ruido

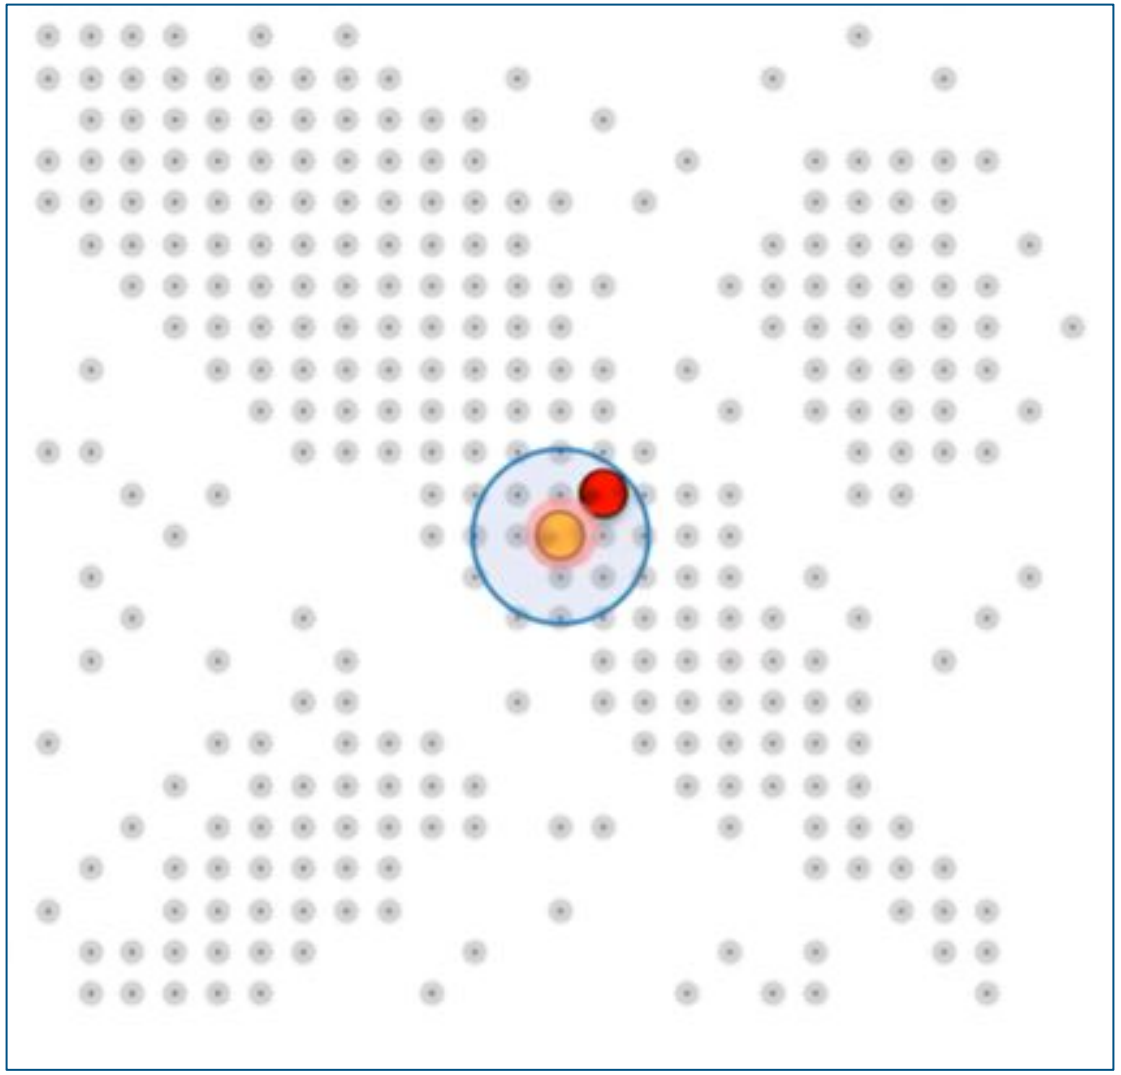




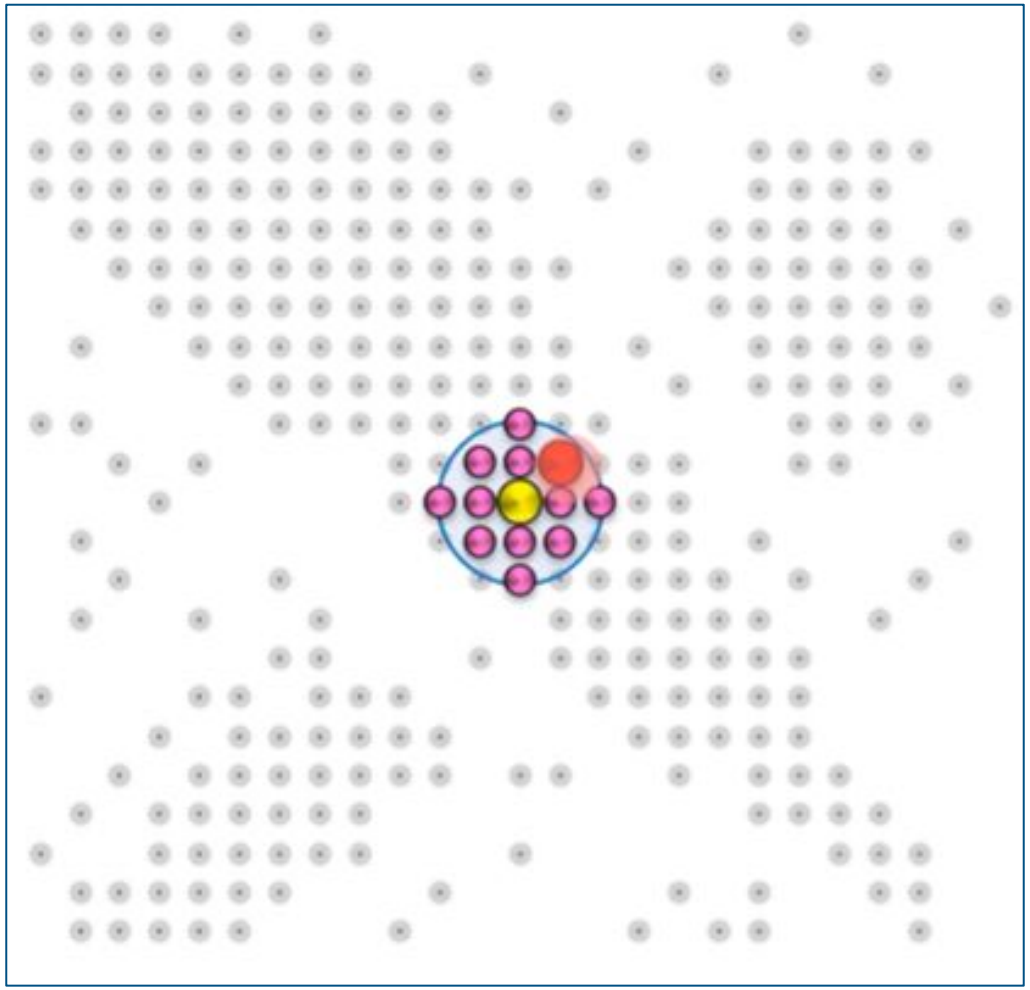
MinPts=10 → **Core Point**



Core Point



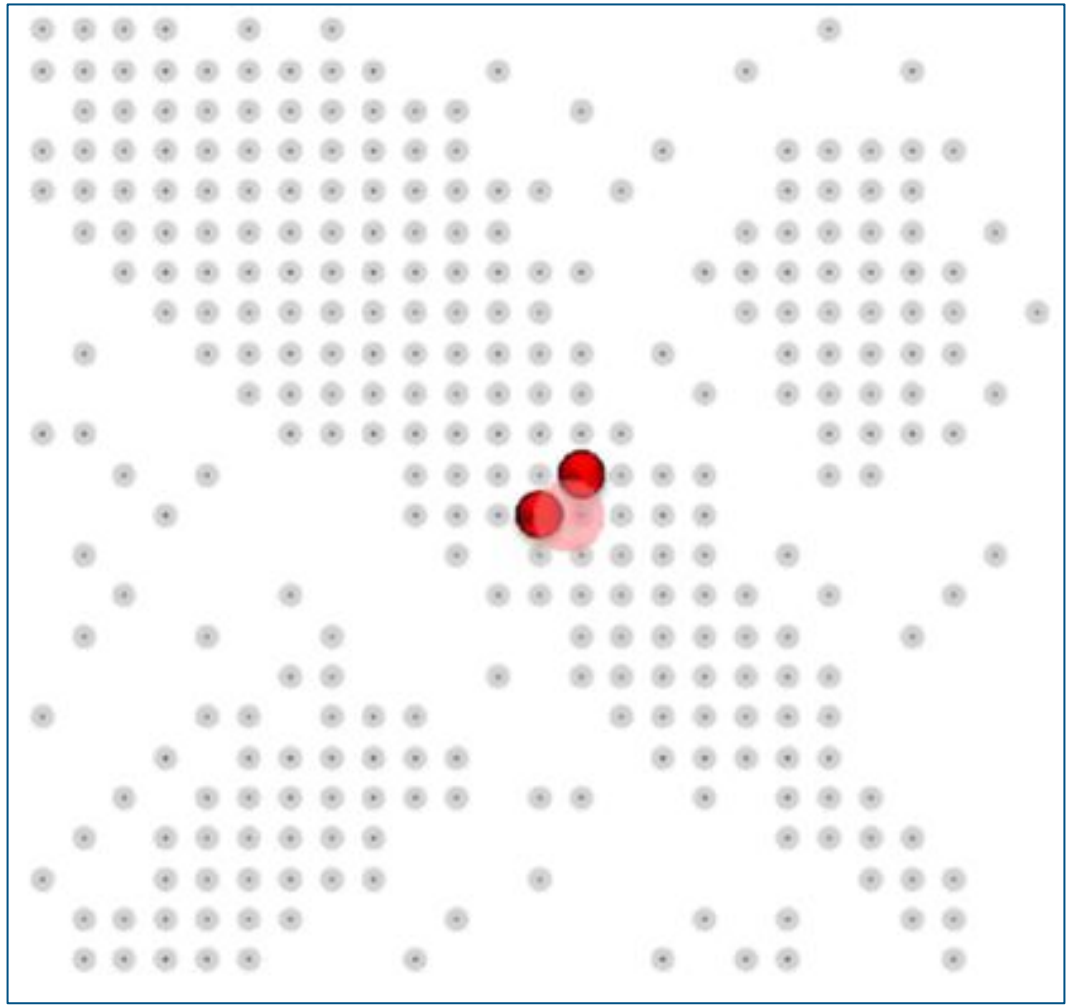
Siguiente punto $(\varepsilon) = 2$



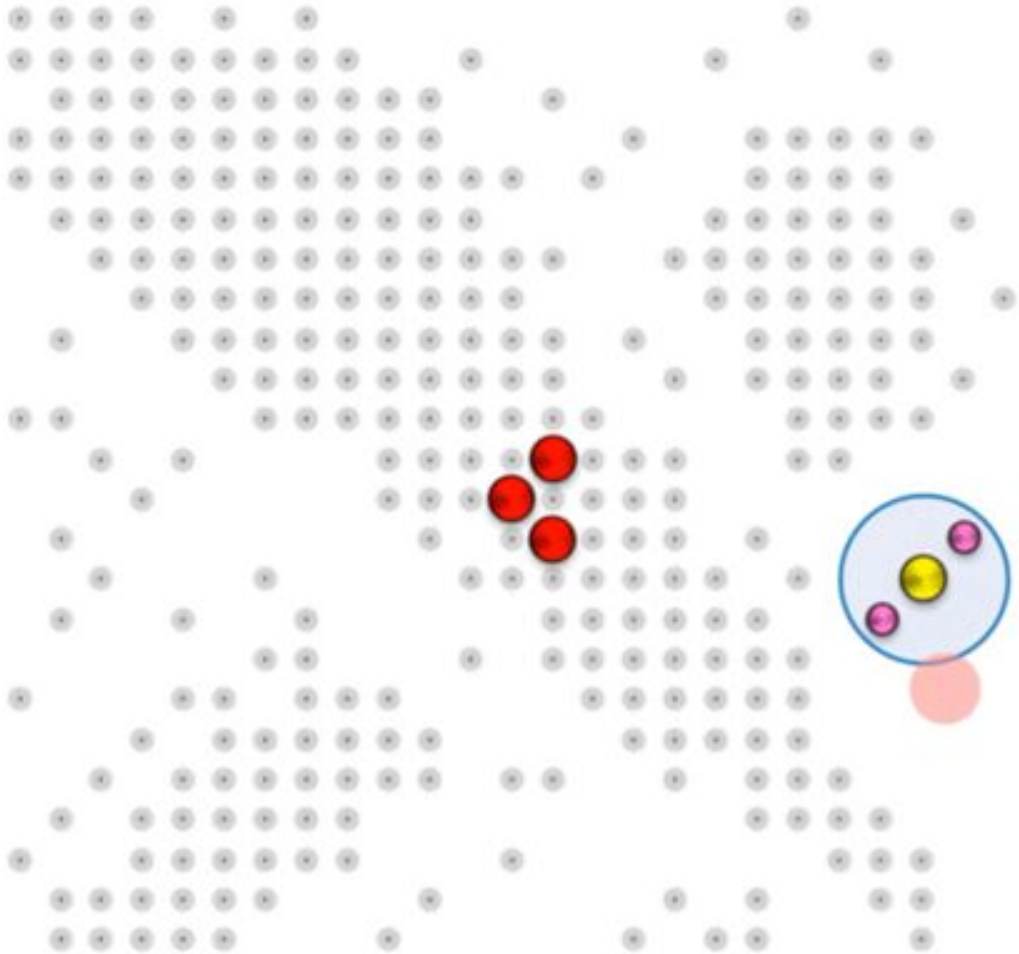
e =2

MinPts =10

→ Core Point



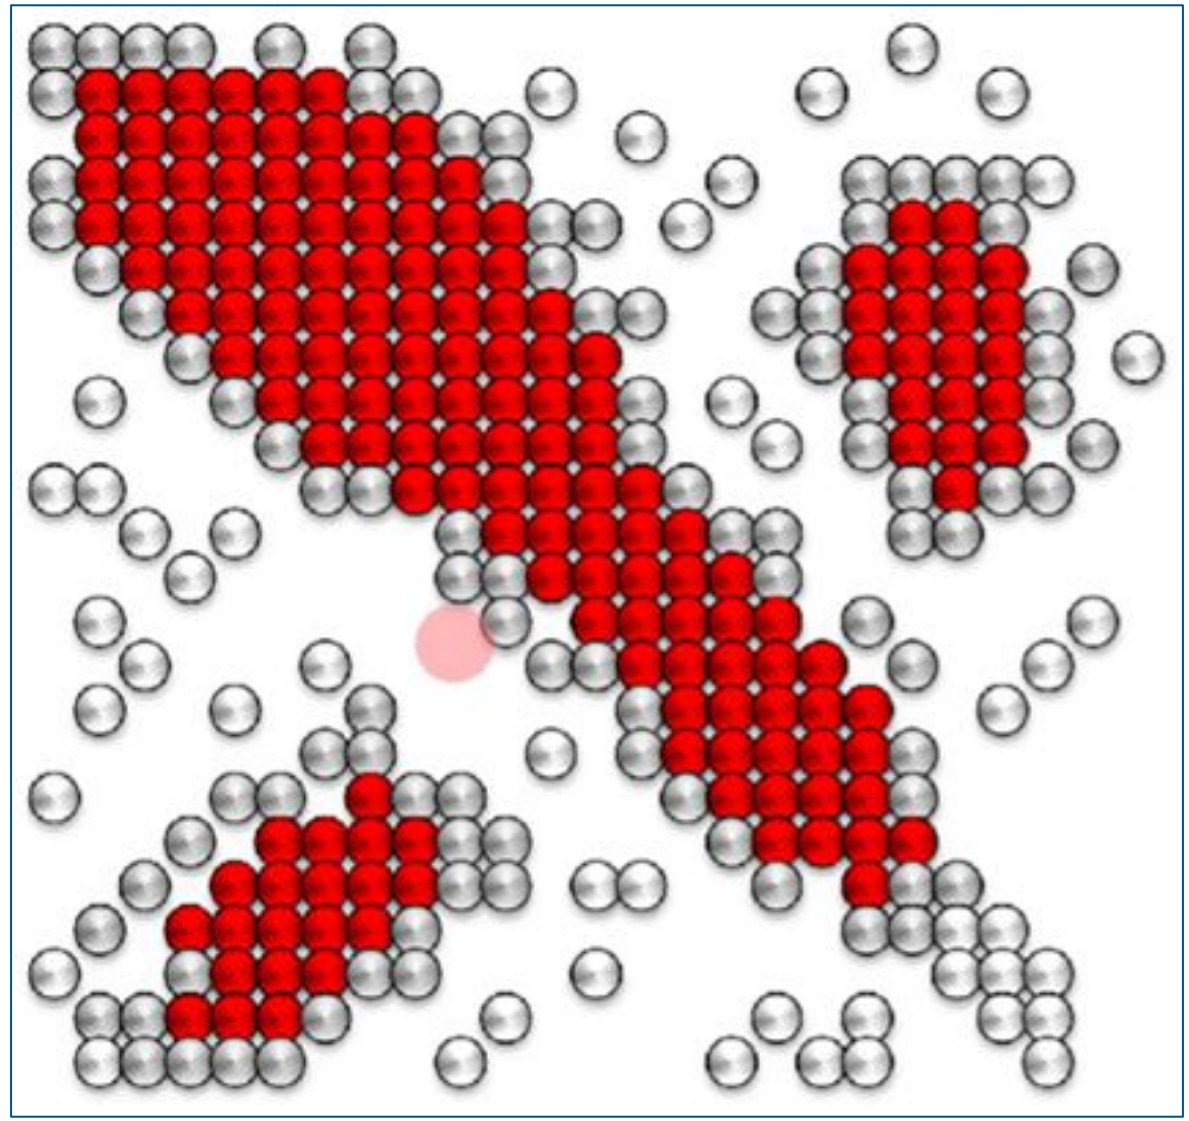
Core Point



e =2

MinPts =10

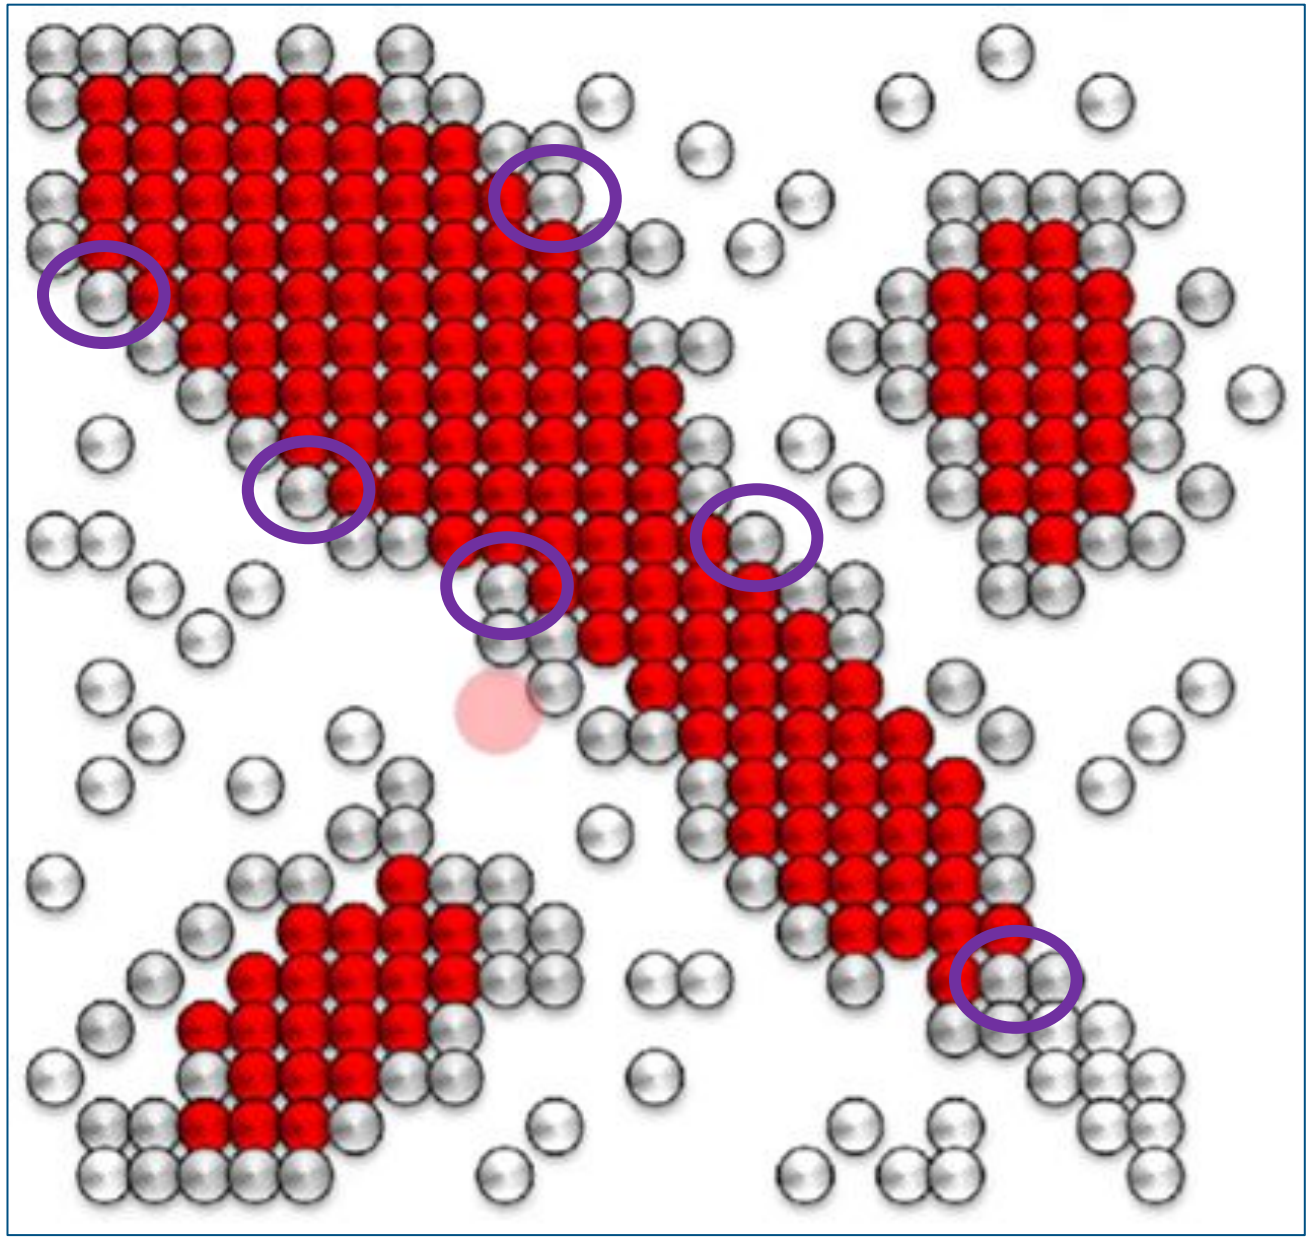
→ Noise Point

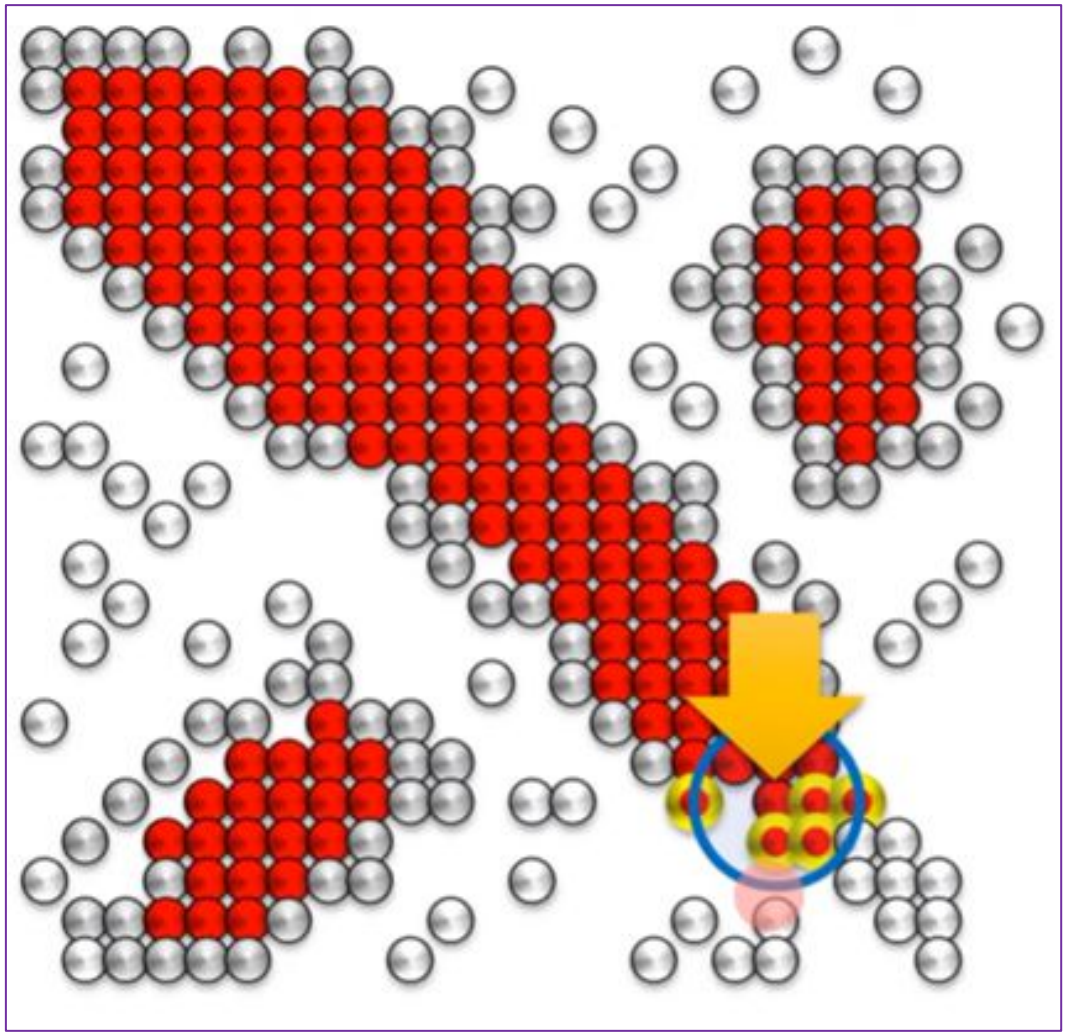


Border Point

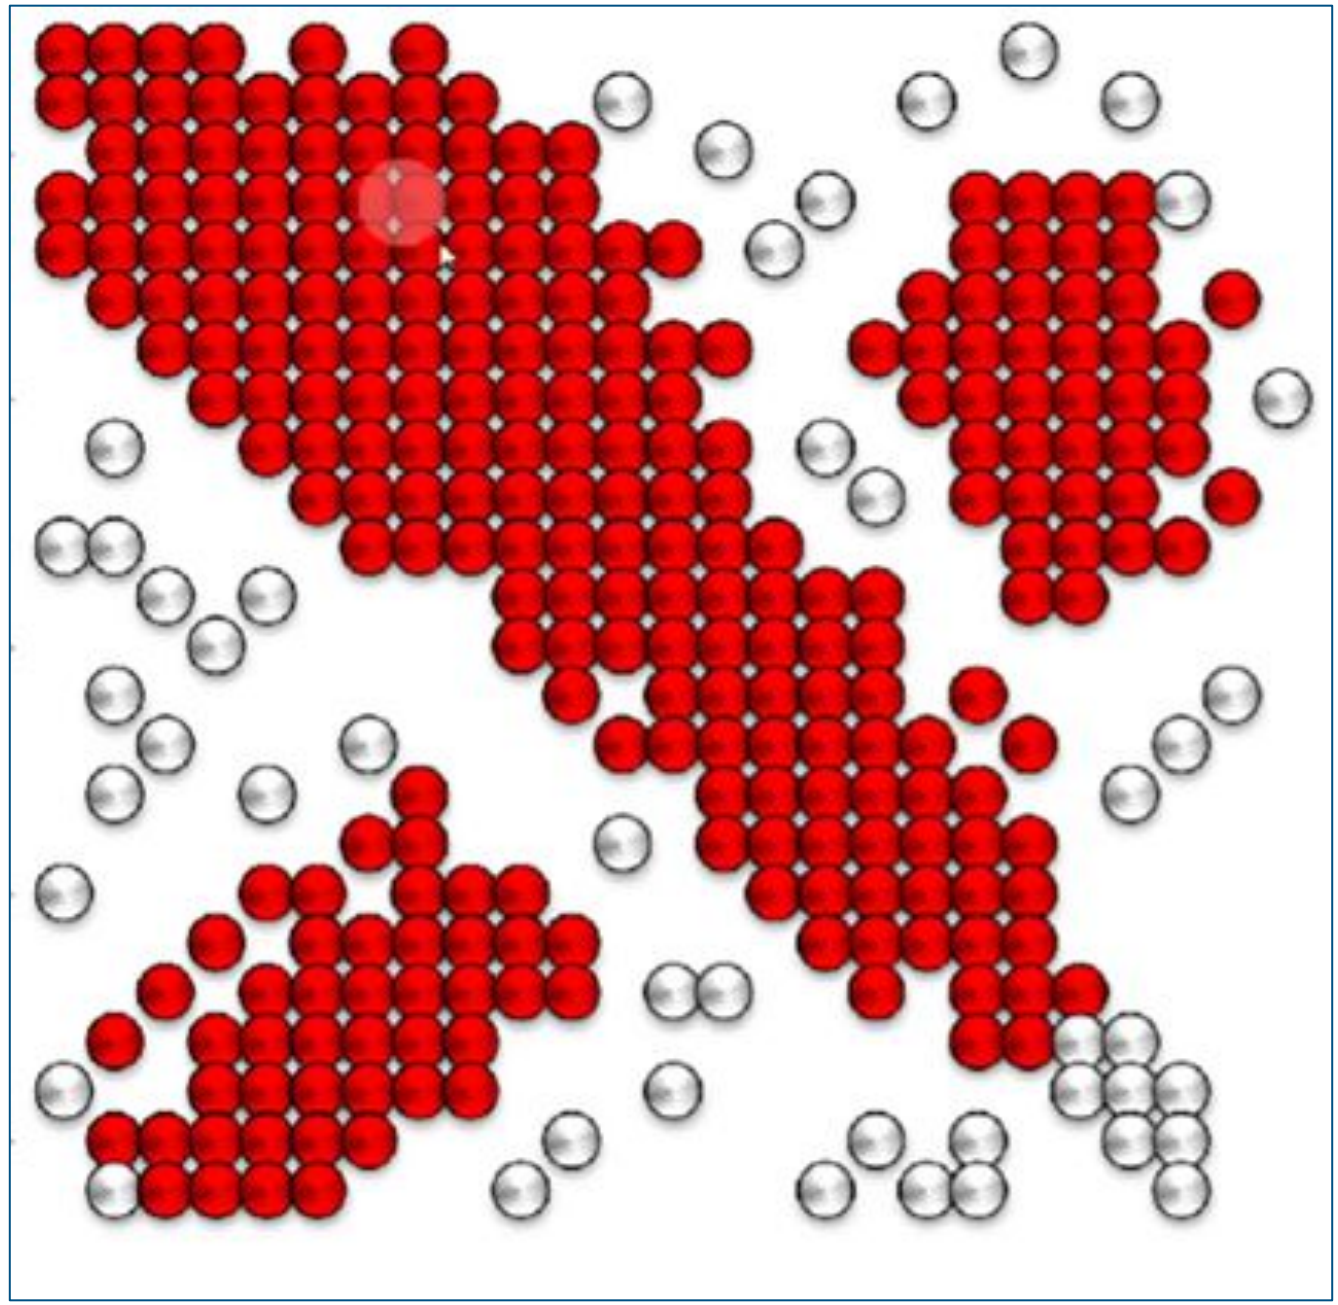
NO tiene suficientes vecinos dentro del radio ε → por eso NO puede ser un core point.

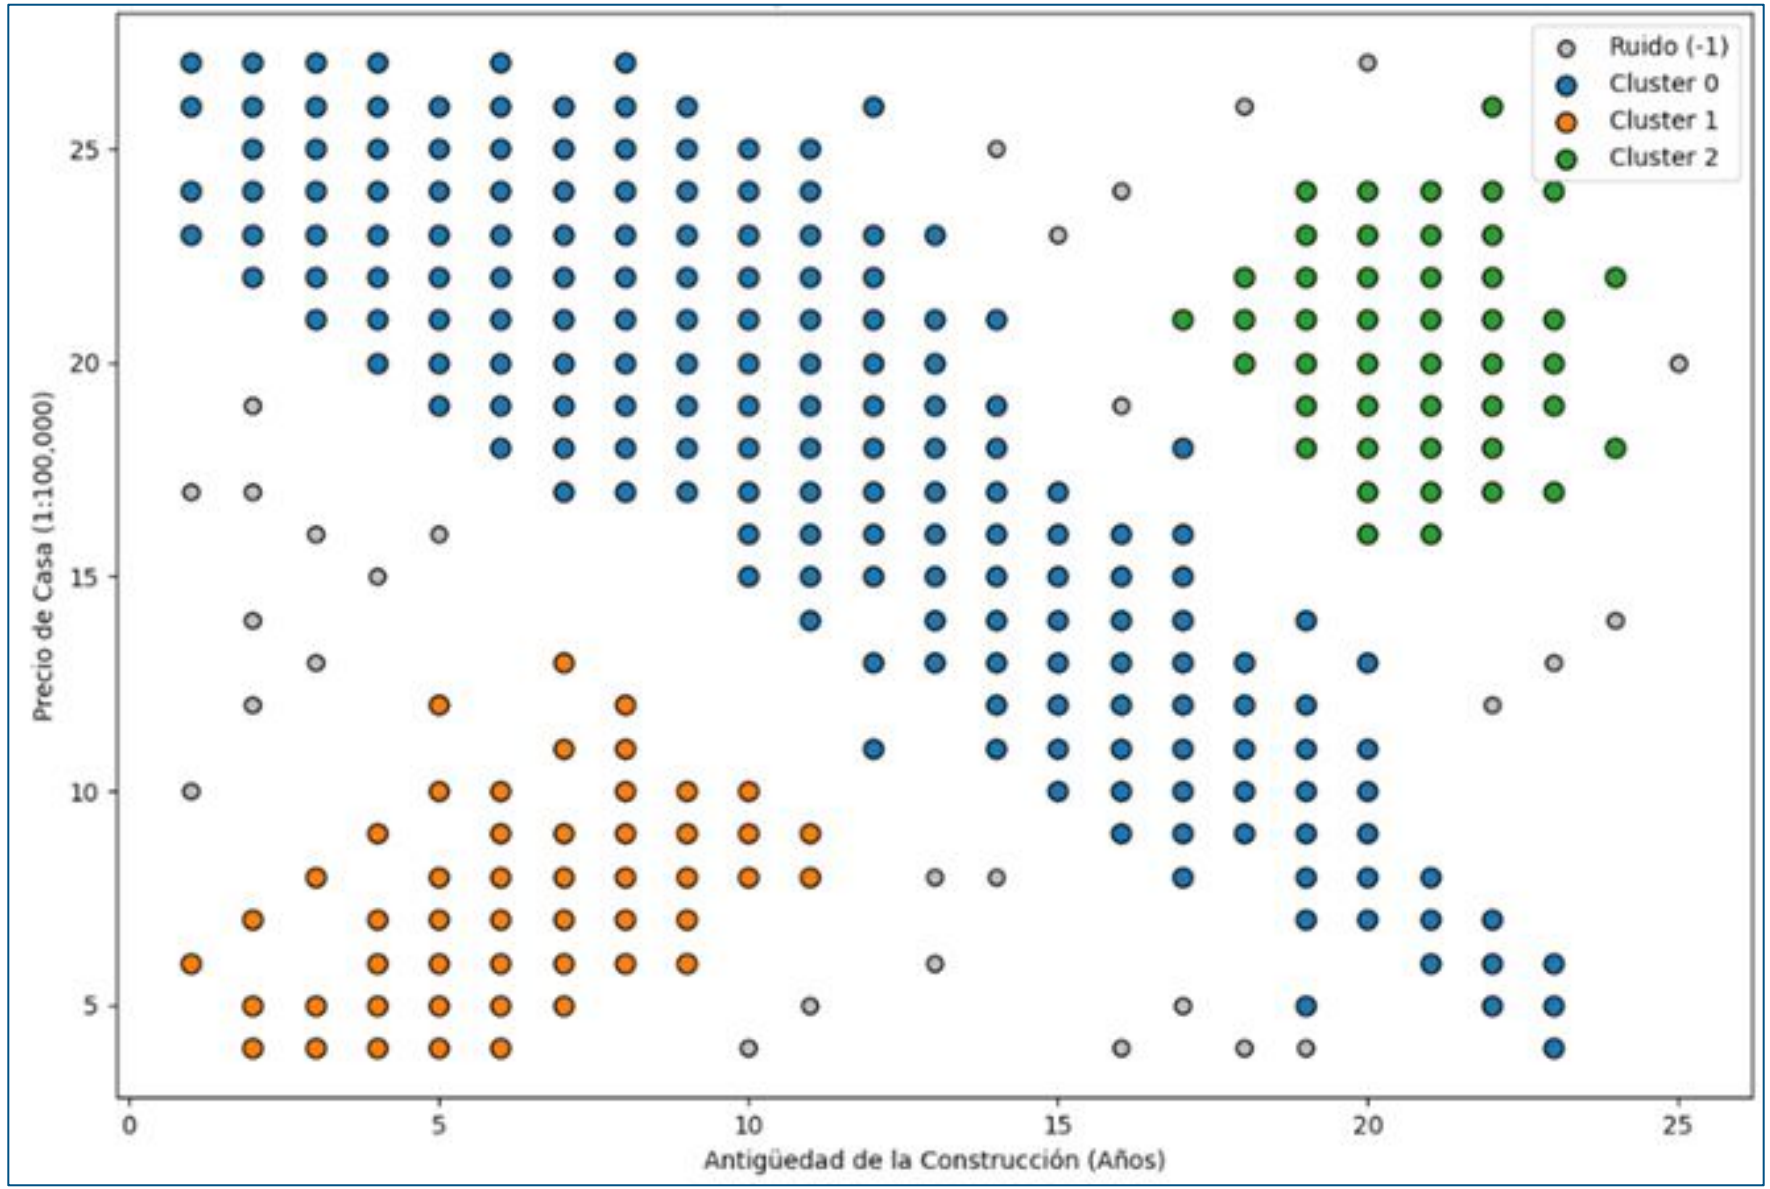
PERO está dentro del vecindario ε de un core point → por eso SÍ pertenece al cluster.



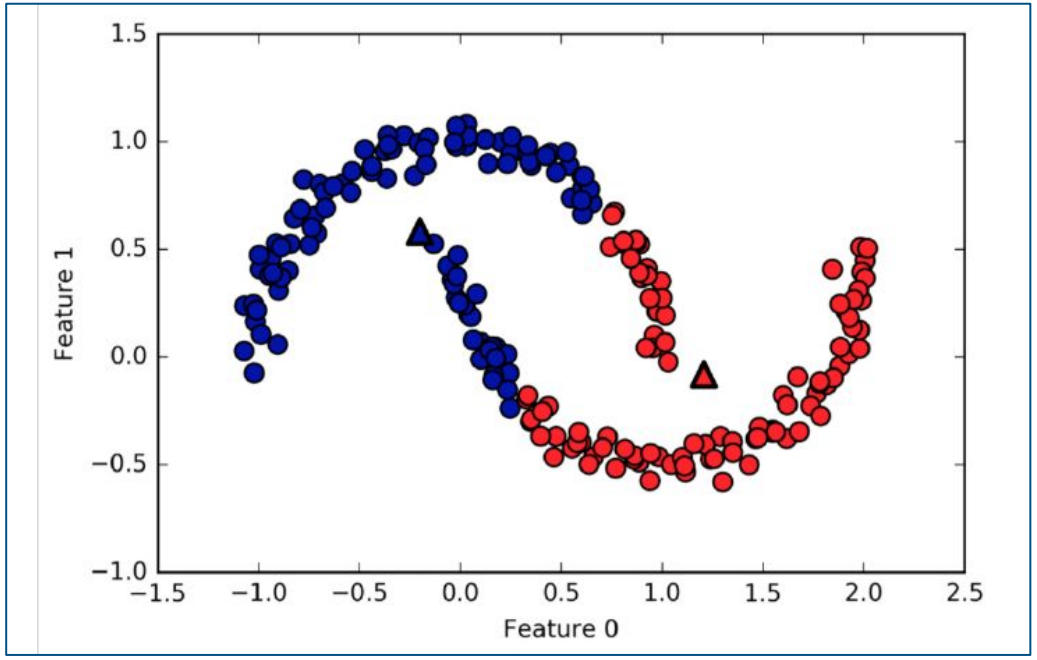


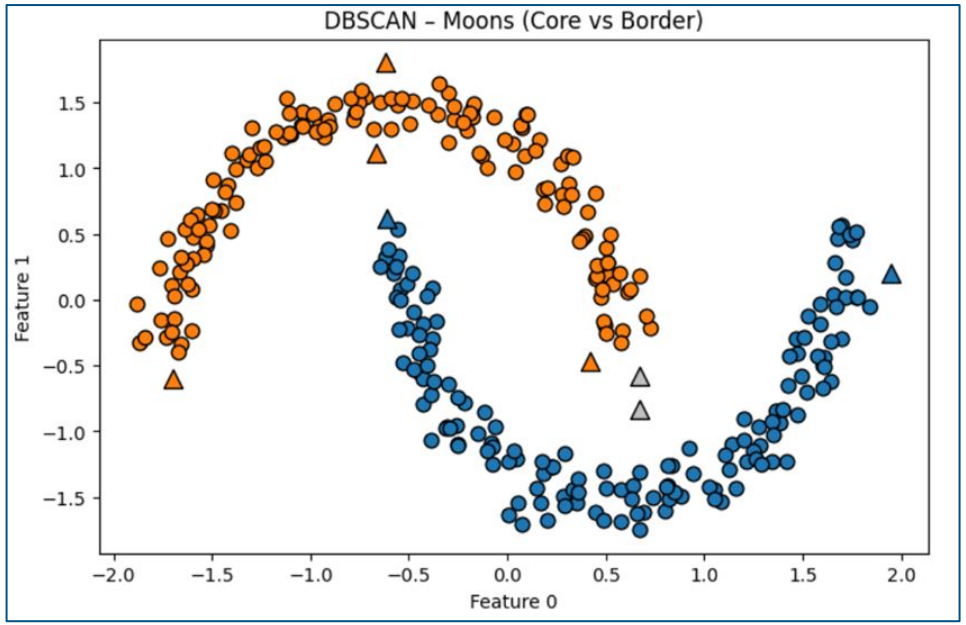
Un Border Point está en el borde del cluster:
No tiene suficiente densidad por sí mismo, **pero está lo suficientemente cerca de un Core Point como para ser parte del cluster.**




Ruido (-1)
Cluster 0
Cluster 1
Cluster 2
Precio de Casa (1:100,000)
Antigüedad de la Construcción (Años)
0
5
10
15
20
25

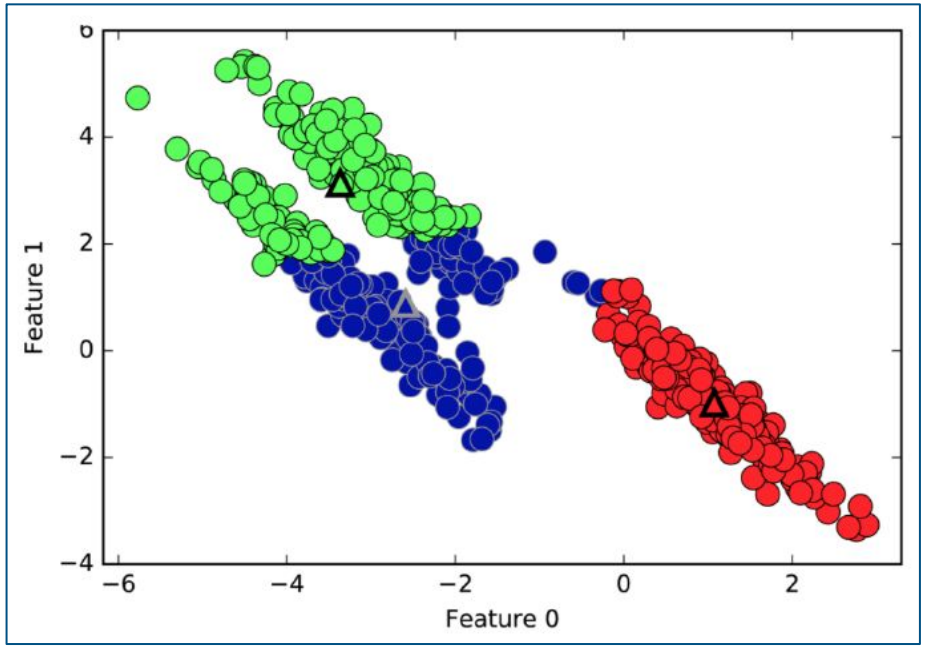
Estas dos imágenes demuestran **por qué DBSCAN es tan poderoso**:
Detecta clusters de **cualquier forma** (no necesita que sean circulares).
Identifica **core**, **border** y **noise**.
No necesita definir K.
Es robusto a ruido.

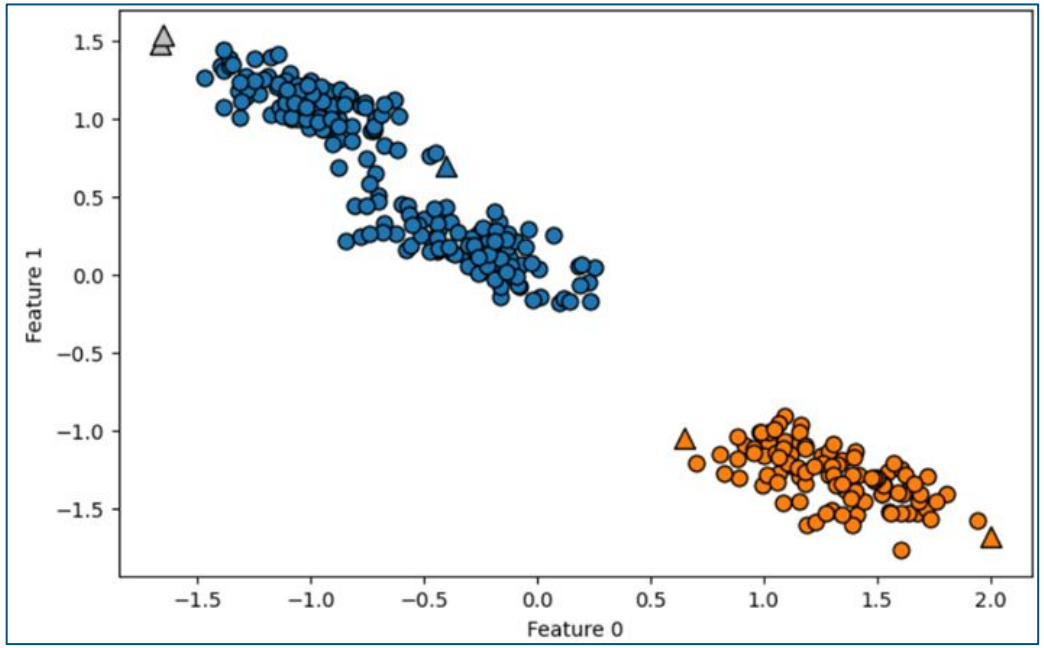




Estas dos imágenes demuestran **por qué DBSCAN es tan poderoso**:
Detecta clusters de **cualquier forma** (no necesita que sean circulares).
Identifica **core**, **border** y **noise**.
No necesita definir K.
Es robusto a ruido.

K-means no puede resolver correctamente ninguno de los dos ejemplos previos.





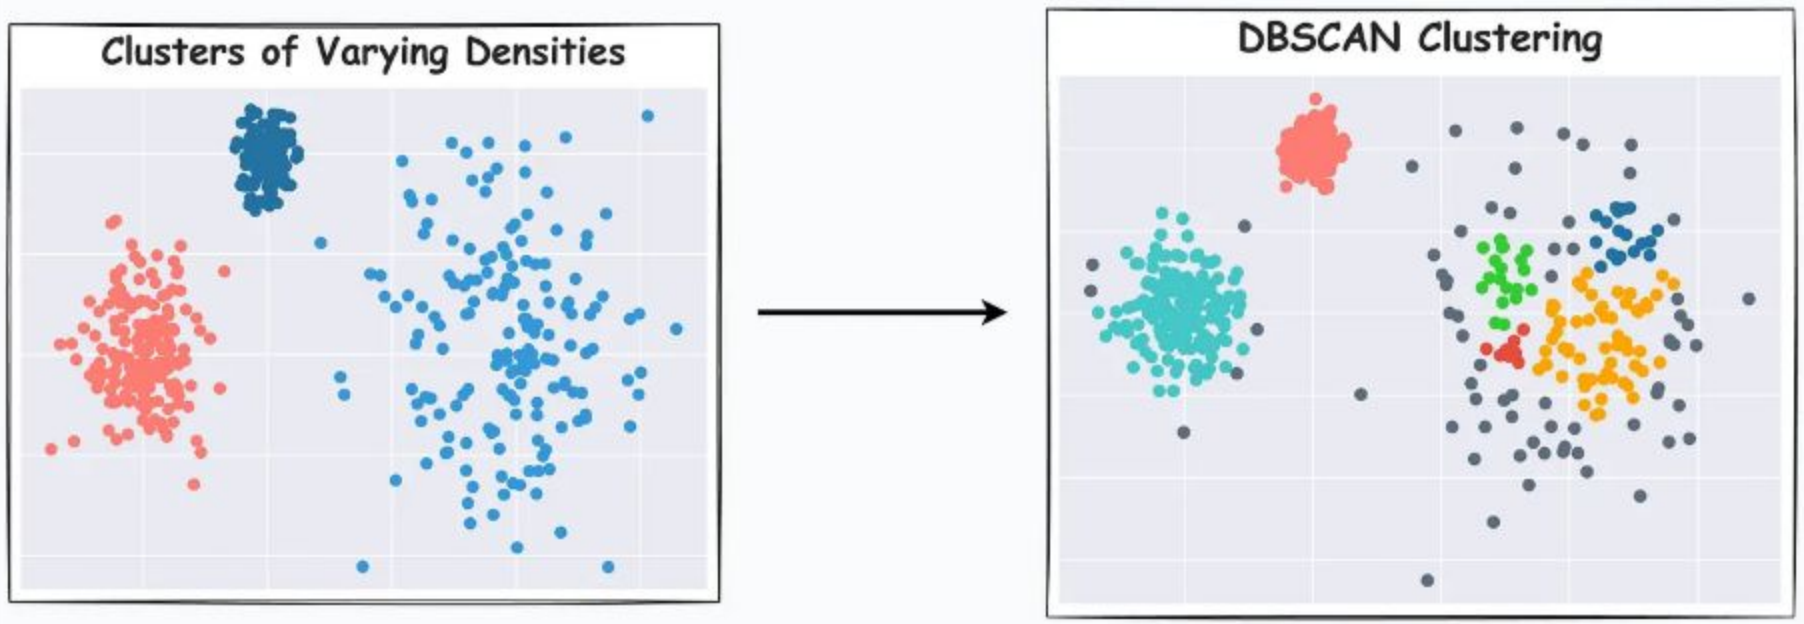
Hierarchical Density-Based Spatial Clustering of Applications with Noise (HDBSCAN)

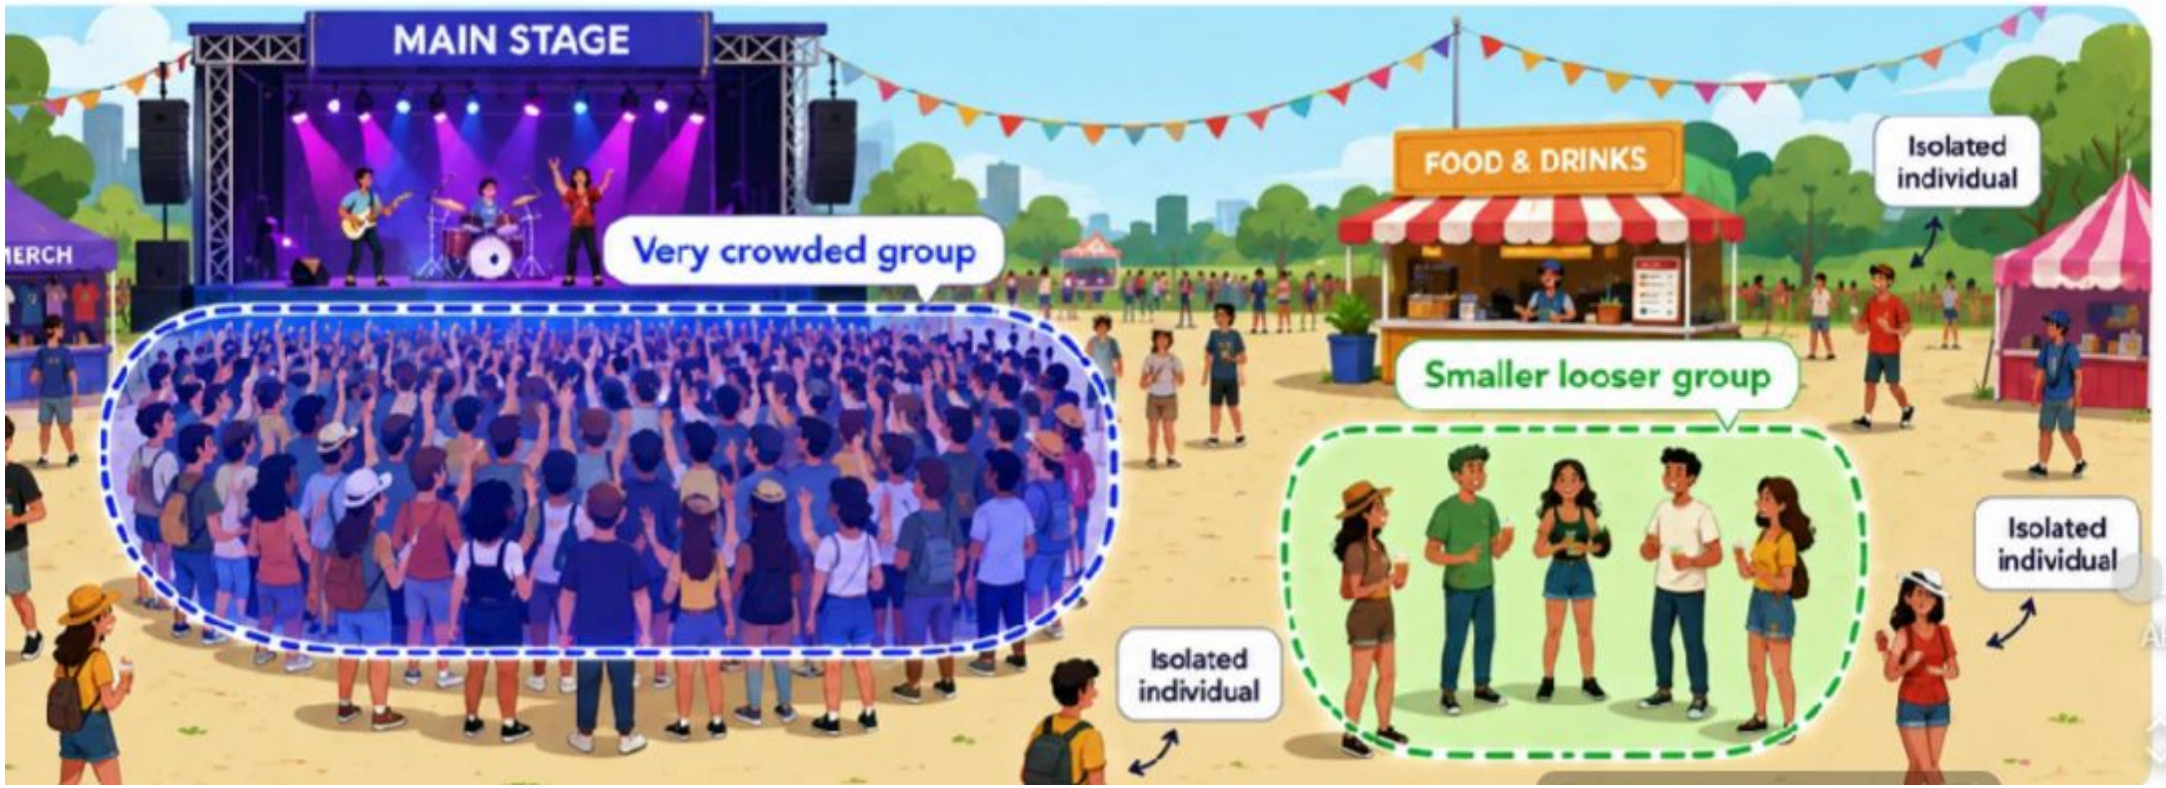
Agrupamiento espacial jerárquico de aplicaciones con ruido basado en densidad (HDBSCAN)

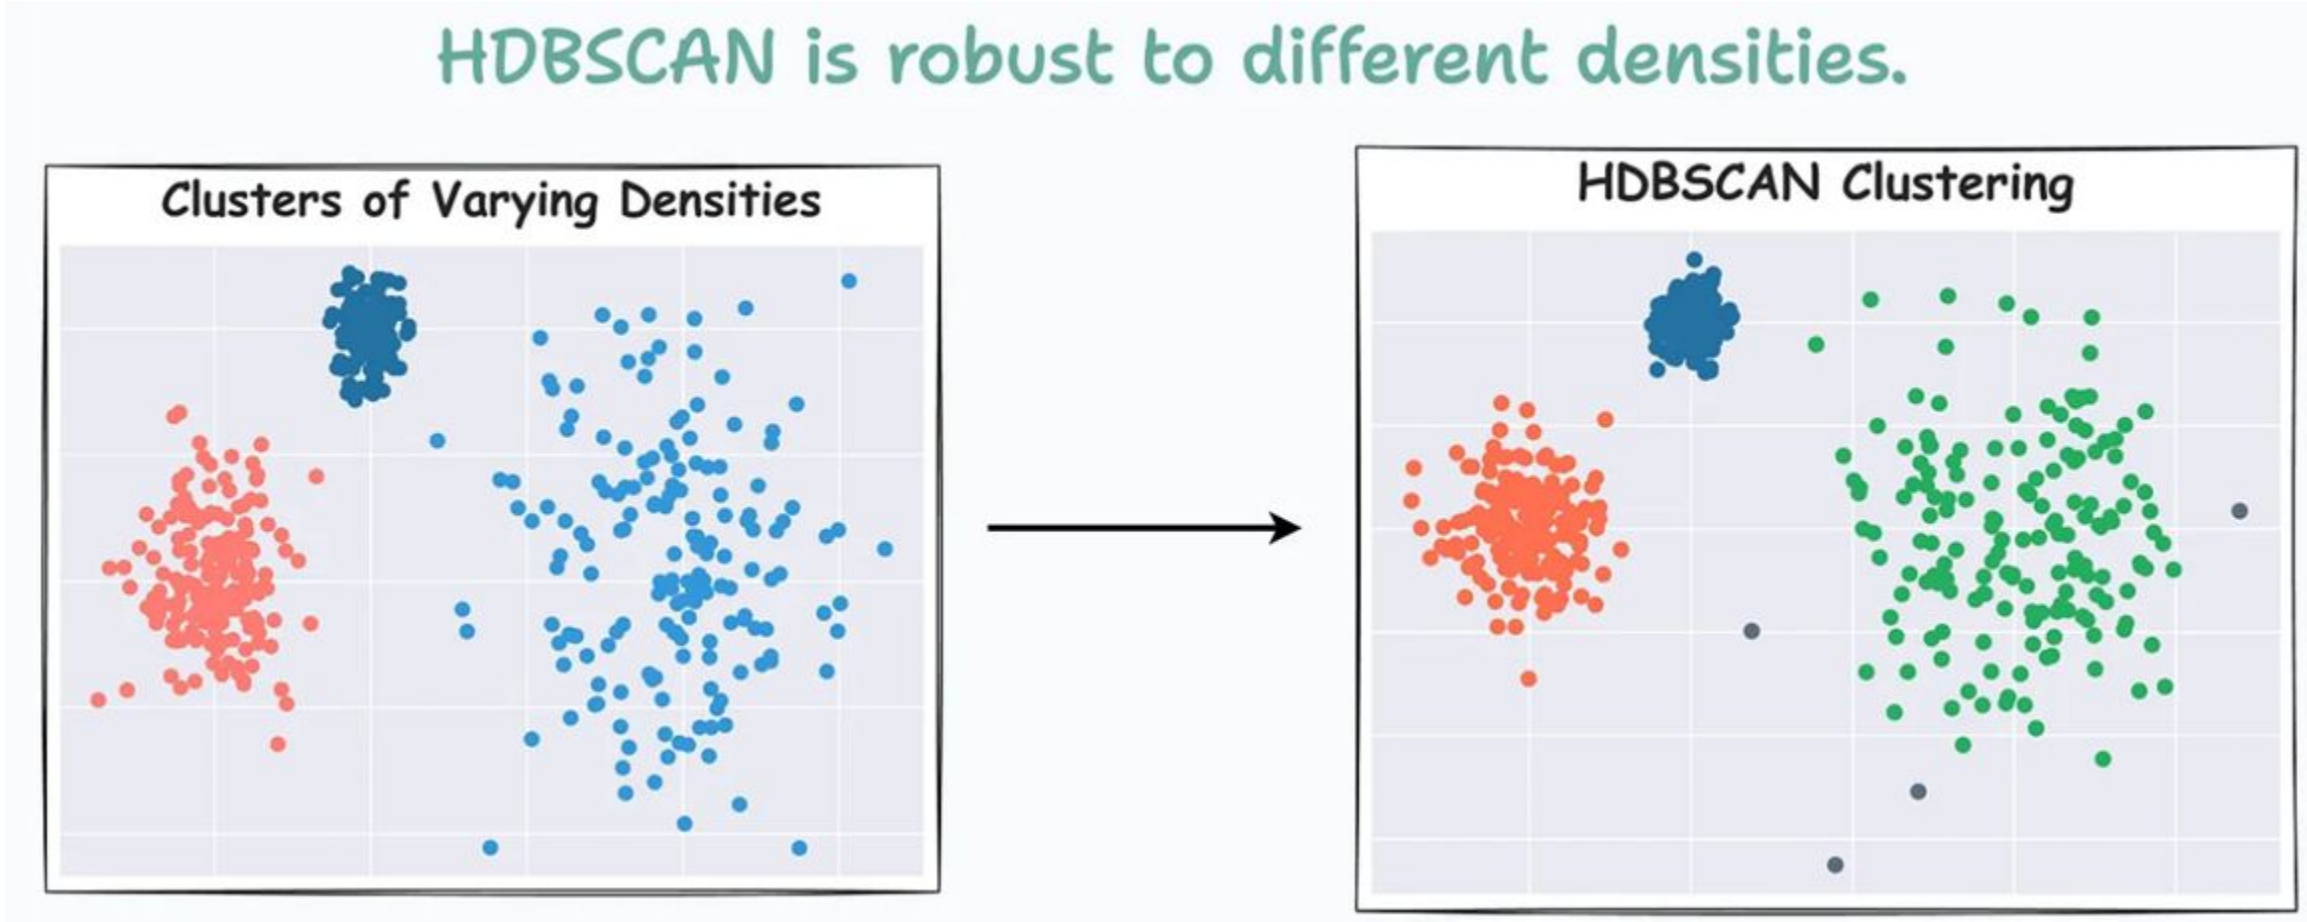
HDBSCAN es un algoritmo de agrupamiento que extiende DBSCAN al hacerlo jerárquico para manejar grupos de densidades y formas variables, y es menos sensible al ajuste de parámetros.

Funciona construyendo una jerarquía de grupos y luego condensándola para identificar grupos estables, lo que lo hace útil para el análisis exploratorio de datos y grandes conjuntos de datos.

DBSCAN struggles with different densities.




MAIN STAGE
FOOD & DRINKS
Very crowded group
Smaller looser group
Isolated individual
Isolated individual
Isolated individual



- Por otro lado, HDBSCAN es invariante a la escala. Por lo tanto, los resultados de la agrupación se mantienen iguales en diferentes escalas de datos.

Creación de jerarquías: HDBSCAN comienza creando una jerarquía de clústeres. Consiste en apilar clústeres, **empezando por los más pequeños y densos** y fusionándolos en clústeres **más grandes a medida que disminuye la densidad**.

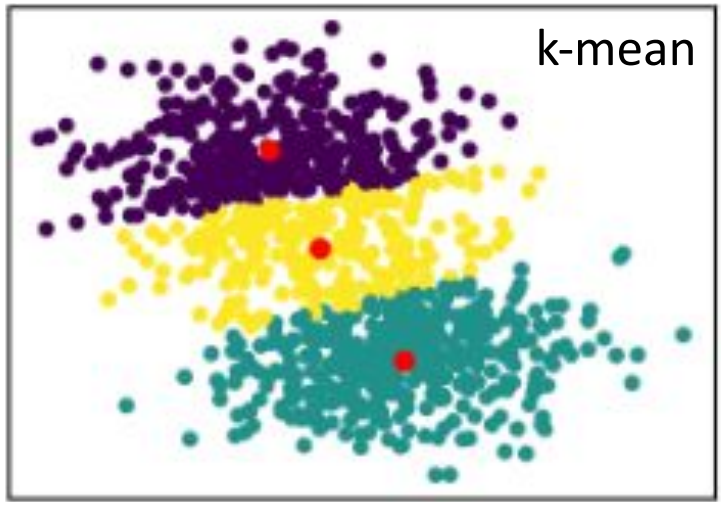
Estabilidad de los clústeres: Una vez creada la jerarquía, HDBSCAN busca los clústeres más estables, aquellos que se mantienen en un rango de niveles de densidad. Estos son los clústeres que nos interesan.

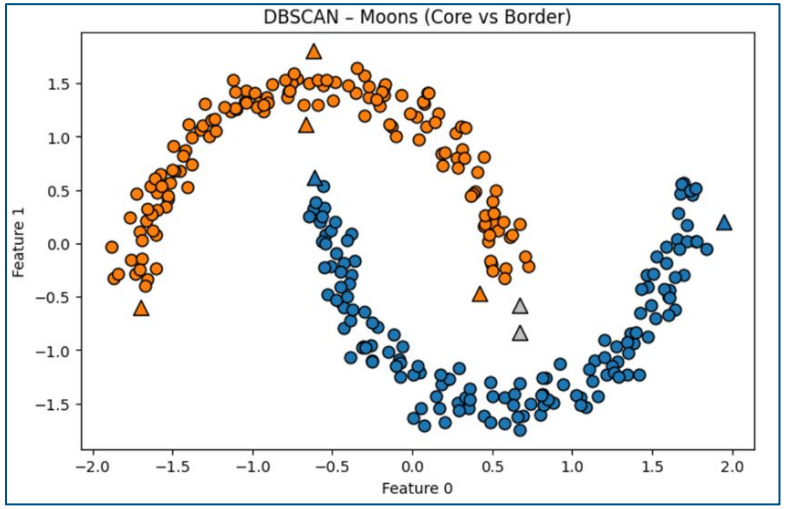


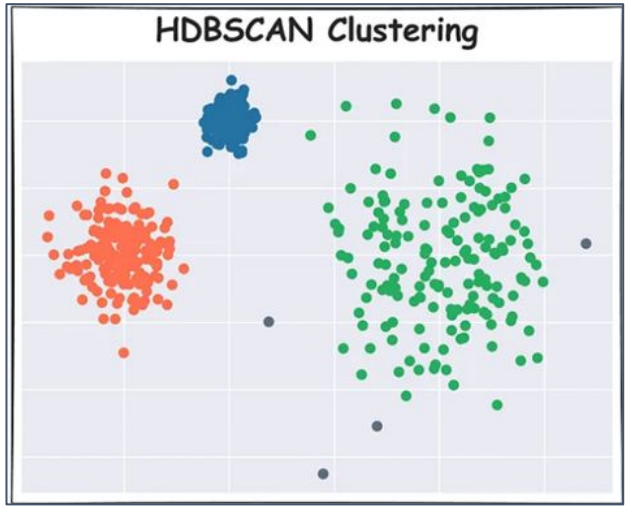
3. Aplicaciones de ML en Agrupación

3.1 Revisión de modelos

3.2 Modelos Gaussianos Mixtos

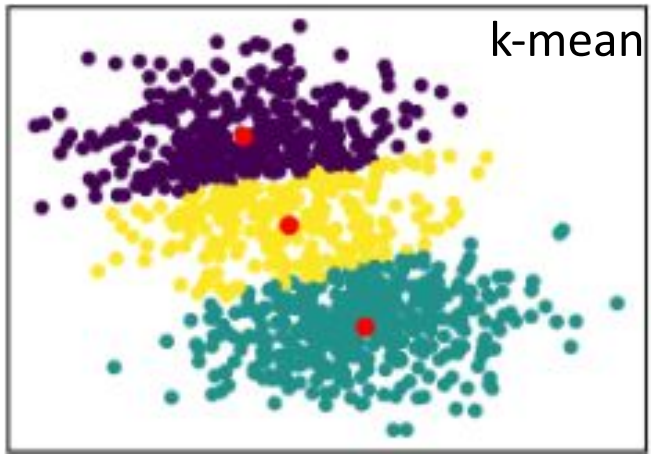


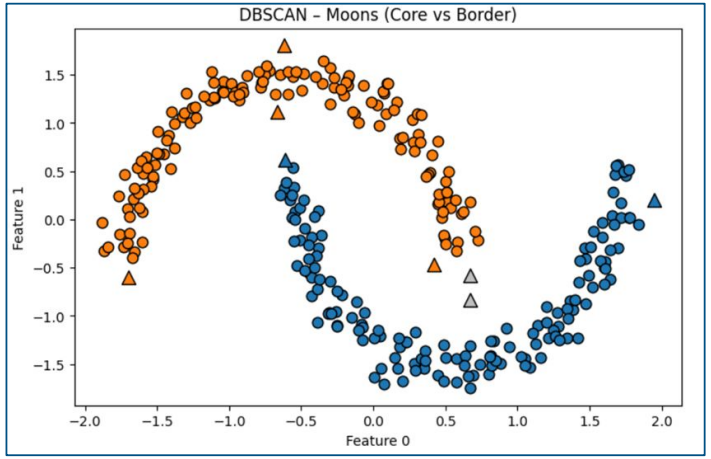


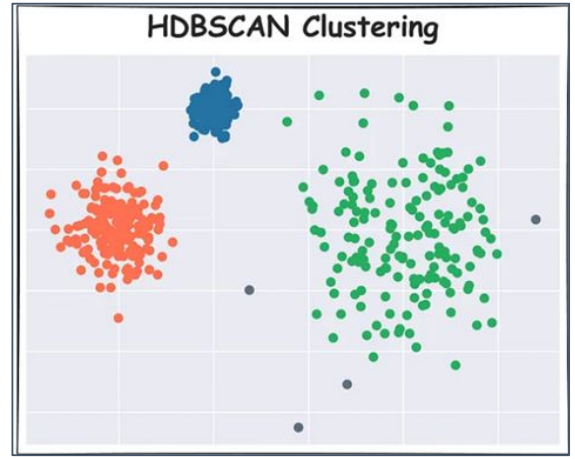


Hasta ahora cada punto ha sido asignado de forma dura, a un único cluster.

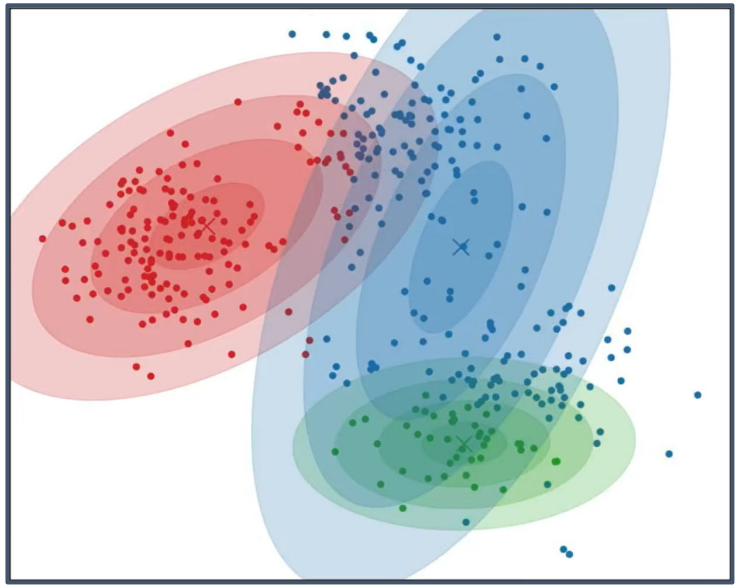
Los Modelos de Mezclas Gaussianas (GMM) cambian el enfoque.
Asignación suave, cada punto recibe una probabilidad de pertenecer a cada cluster, por ejemplo:
Un punto tiene 60% de probabilidad de pertenecer al cluster A y 40% al cluster B.

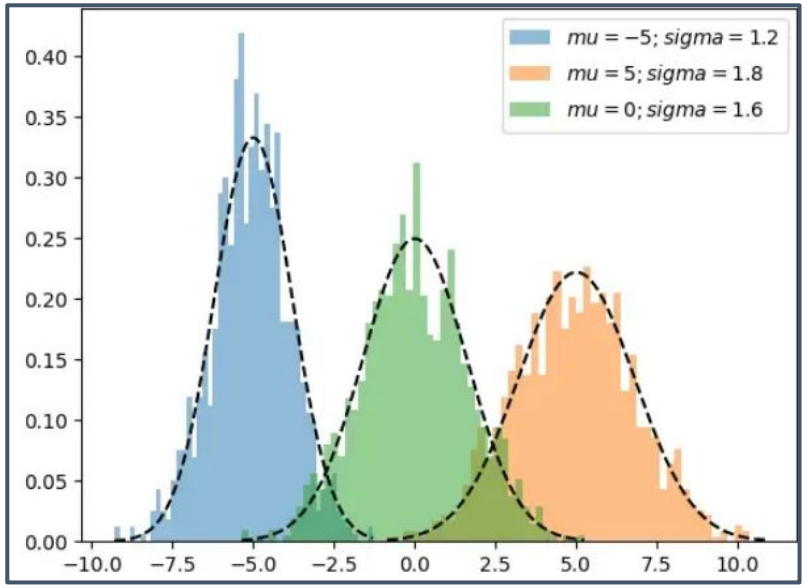






Los Modelos de Mezclas Gaussianas (GMM) realizan asignación suave, cada punto recibe una probabilidad de pertenecer a cada cluster.





Gaussiana de una variable:

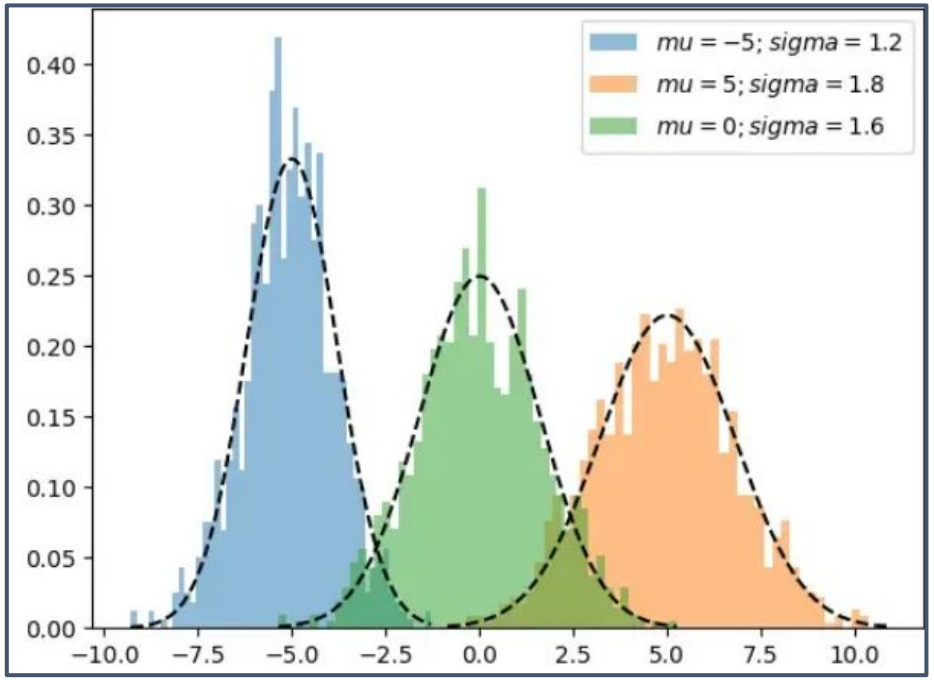
$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

Gaussiana Multivariada:

$$P(X) = \sum_{k=1}^{K} \pi_k \mathcal{N}(X|\mu_k, \Sigma_k)$$

La idea detrás de GMM: La distribución Gaussiana (Normal)

GMM asume que los datos son generados por una combinación de varias distribuciones gaussianas.



Cada cluster es una "campana gaussiana" y los datos son la combinación de varias campanas.

La idea detrás de GMM: La distribución Gaussiana (Normal)

GMM asume que los datos son generados por una combinación de varias distribuciones gaussianas.

$$P(X) = \sum_{k=1}^{K} \pi_k \mathcal{N}(X|\mu_k, \Sigma_k)$$

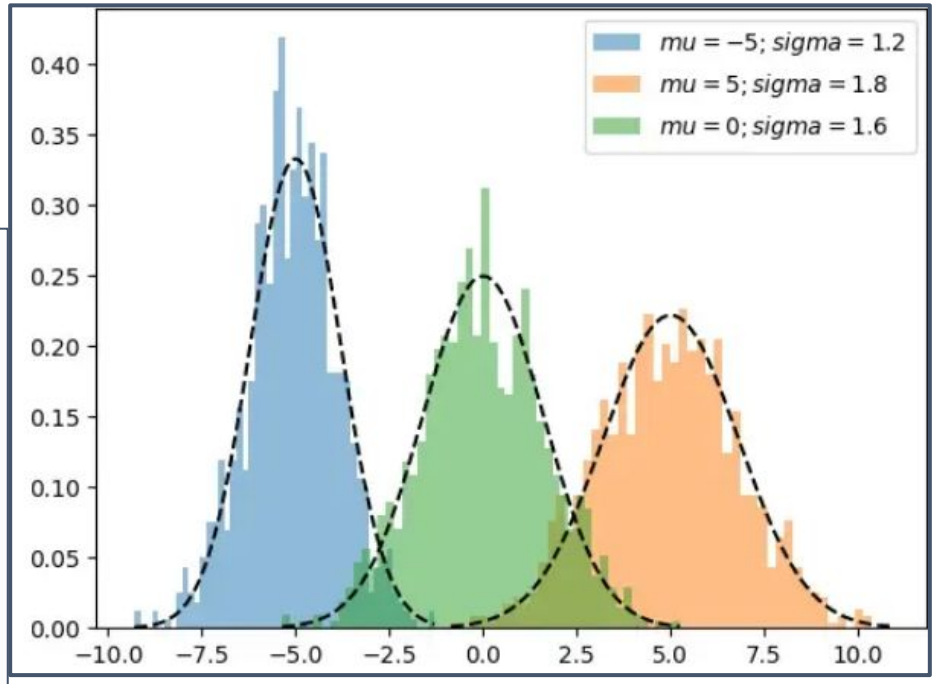
K **(número de clusters):** Representa la cantidad total de grupos o clusters en los que se dividen los datos.

π_k **(peso de mezcla / proporción):** Es la probabilidad a priori y proporción de que un punto pertenezca al cluster k, la cual cumple que $\sum \pi_k = 1$ y $\pi_k \geq 0$.

μ_k **(media):** Es el centro de la distribución del cluster k, análogo al centroide en el algoritmo K-Means.

Σ_k **(covarianza / matriz de covarianza):** Define la forma, tamaño y orientación de la nube de puntos que conforma el cluster k.

$\mathcal{N}$ **(distribución normal):** Representa la función de densidad de probabilidad gaussiana o normal asignada a los componentes de la mezcla.



Cada cluster es una "campana gaussiana" y los datos son la combinación de varias campanas.

Gaussiana Multivariada:
Forma compacta

$$P(X) = \sum_{k=1}^{K} \pi_k \mathcal{N}(X|\mu_k, \Sigma_k)$$

K = 3 clústeres:

$$P(X) = \pi_1 \mathcal{N}(X \mid \mu_1, \Sigma_1) + \pi_2 \mathcal{N}(X \mid \mu_2, \Sigma_2) + \pi_3 \mathcal{N}(X \mid \mu_3, \Sigma_3)$$

Término 1 ($\pi_1 \mathcal{N}(X \mid \mu_1, \Sigma_1)$): La densidad de probabilidad del primer clúster, ponderada por su peso de mezcla (π_1).

Término 2 ($\pi_2 \mathcal{N}(X \mid \mu_2, \Sigma_2)$): La densidad de probabilidad del segundo clúster, ponderada por su peso (π_2).

Término 3 ($\pi_3 \mathcal{N}(X \mid \mu_3, \Sigma_3)$): La densidad de probabilidad del tercer clúster, ponderada por su peso (π_3).

Gaussiana Multivariada: Forma desarrollada

$$P(X) = \sum_{k=1}^{K} \pi_k \left(\frac{1}{(2\pi)^{d/2}|\Sigma_k|^{1/2}} e^{-\frac{1}{2}(X-\mu_k)^T \Sigma_k^{-1}(X-\mu_k)} \right)$$

K = 3 clústeres:

$$P(X) = \pi_1 \left(\frac{1}{(2\pi)^{d/2}|\Sigma_1|^{1/2}} e^{-\frac{1}{2}(X-\mu_1)^T \Sigma_1^{-1}(X-\mu_1)} \right) +$$

$$\pi_2 \left(\frac{1}{(2\pi)^{d/2}|\Sigma_2|^{1/2}} e^{-\frac{1}{2}(X-\mu_2)^T \Sigma_2^{-1}(X-\mu_2)} \right) +$$

$$\pi_3 \left(\frac{1}{(2\pi)^{d/2}|\Sigma_3|^{1/2}} e^{-\frac{1}{2}(X-\mu_3)^T \Sigma_3^{-1}(X-\mu_3)} \right)$$

Tomemos el 1er término/cluster, k=1:

$$\pi_1 \left(\frac{1}{(2\pi)^{d/2}|\Sigma_1|^{1/2}} e^{-\frac{1}{2}(X-\mu_1)^T \Sigma_1^{-1}(X-\mu_1)} \right)$$

$|\Sigma_1|$ **Determinante** de la matriz de covarianza de las variables predictoras.
Un determinante grande indica una nube de puntos dispersa.
Caso contrario una nube de datos concentrada.

Σ_1^{-1} Inversa de la matriz de covarianza.
La multiplicación $(X-\mu_1)^T$ y $(X-\mu_1)$ representa la distancia Mahalanobis.

Asumir dataset con **2 variables predictoras**: X_1, X_2; (d=2).

mu_1,1: Es la media de la variable X1 en el Cluster 1.

mu_1,2: Es la media de la variable X2 en el Cluster 1.

$$X = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad \mu_1 = \begin{bmatrix} \mu_{1,1} \\ \mu_{1,2} \end{bmatrix}$$

Matriz de covarianza Σ_1 para el clúster 1: $\begin{bmatrix} \sigma_{11}^2 & \sigma_{12} \\ \sigma_{21} & \sigma_{12} \end{bmatrix}$

$$\pi_1 \left(\frac{1}{(2\pi)^{d/2} |\Sigma_1|^{1/2}} e^{-\frac{1}{2}(X-\mu_1)^T \Sigma_1^{-1} (X-\mu_1)} \right)$$

$$\pi_1 \cdot \frac{1}{2\pi\sqrt{|\Sigma_1|}} e^{-\frac{1}{2}\begin{bmatrix} x_1 - \mu_{1,1} & x_2 - \mu_{1,2} \end{bmatrix} \begin{bmatrix} \sigma_{11}^2 & \sigma_{12} \\ \sigma_{21} & \sigma_{22}^2 \end{bmatrix}^{-1} \begin{bmatrix} x_1 - \mu_{1,1} \\ x_2 - \mu_{1,2} \end{bmatrix}}$$

1er término/cluster, k=1

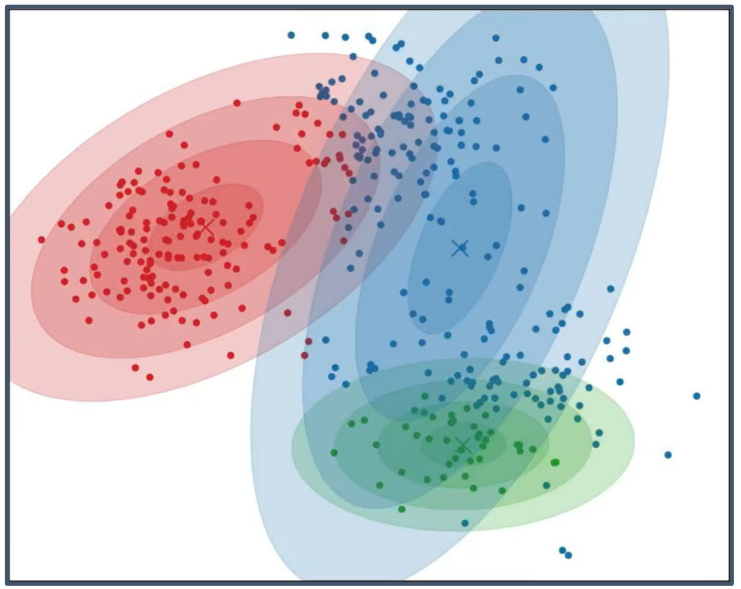
$$\pi_1 \cdot \frac{1}{2\pi\sqrt{|\Sigma_1|}} e^{-\frac{1}{2}\begin{bmatrix} x_1 - \mu_{1,1} & x_2 - \mu_{1,2} \end{bmatrix} \begin{bmatrix} \sigma_{11}^2 & \sigma_{12} \\ \sigma_{21} & \sigma_{22}^2 \end{bmatrix}^{-1} \begin{bmatrix} x_1 - \mu_{1,1} \\ x_2 - \mu_{1,2} \end{bmatrix}}$$

σ_{11}^2 **(Varianza de la variable 1):** Mide la dispersión o anchura del clúster a lo largo del **eje horizontal (X_1)**. Un valor grande expande la nube de puntos horizontalmente; un valor pequeño la estrecha.

σ_{22}^2 **(Varianza de la variable 2):** Mide la dispersión o altura del clúster a lo largo del **eje vertical (X_2)**. Controla qué tan extendida está la nube de puntos verticalmente.

σ_{12} y σ_{21} **(Covarianza entre la variable 1 y la variable 2):** Mide la relación lineal directa entre ambas variables y controla la **orientación / inclinación** de la nube de puntos.

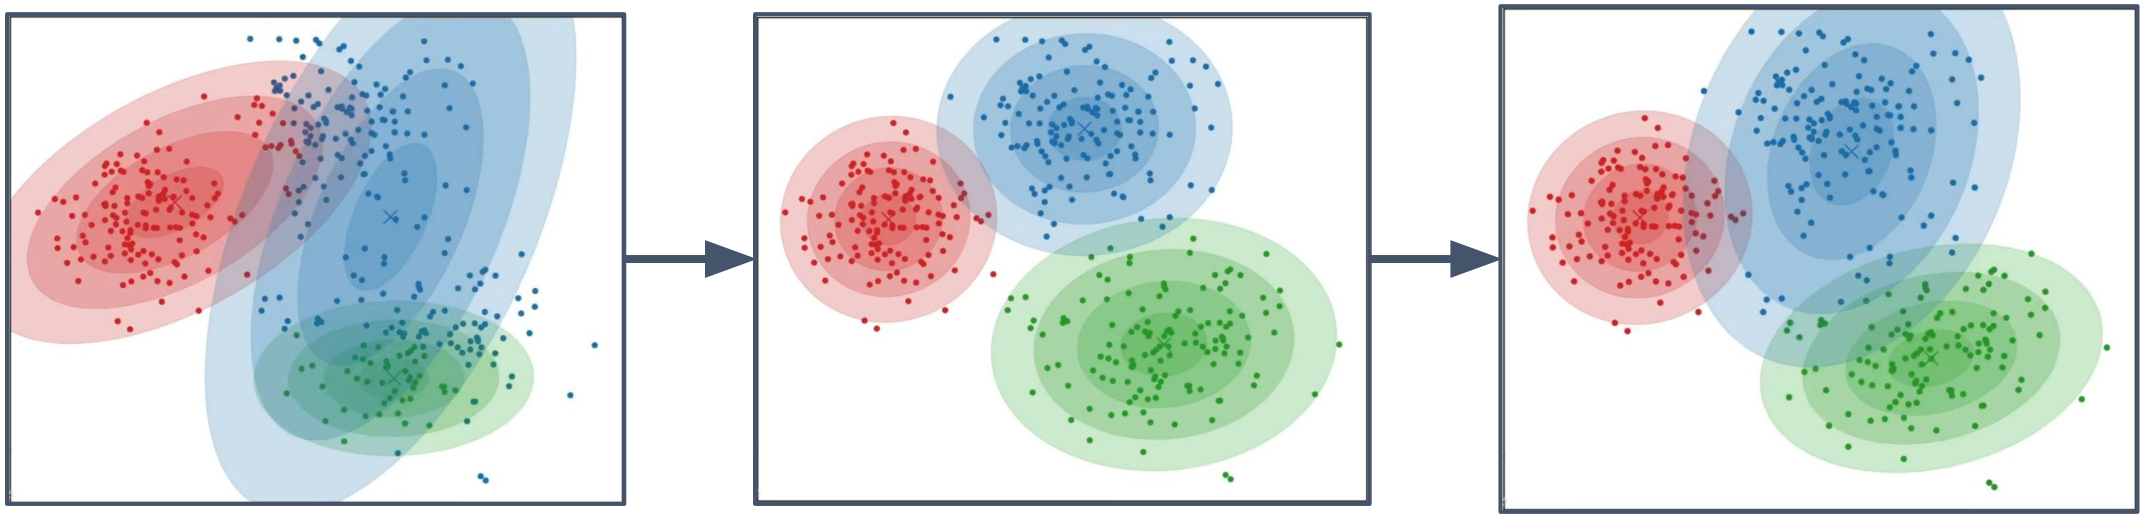
- Si $\sigma_{12} > 0$, la elipse se inclina hacia la derecha (relación positiva).
- Si $\sigma_{12} < 0$, se inclina hacia la izquierda (relación negativa).
- Si $\sigma_{12} = 0$, los ejes de la elipse quedan completamente alineados con los ejes cartesianos (sin inclinación).



Cómo obtener los parámetros de las Gaussianas? π_k, μ_k, Σ_k

Usando el algoritmo de **Expectation-Maximization (EM)**, que es un proceso iterativo que encuentra/optimiza los parámetros de las gaussianas.

Al inicio las Gaussianas se colocan al azar y no encajan bien con los datos. El algoritmo EM moverá, girara y ajustará las gaussianas para cubrir la mayor cantidad de puntos.



Expectation-Maximization (EM)

Paso 0- Inicialización: K-means para obtener los valores iniciales de π_k, μ_k, Σ_k

Paso E- Expectation - calcular responsabilidades:
Para cada punto X_i y cada componente K (cluster), se calcula una responsabilidad **r_ik.**
La suma de los r_ik=1**.**

Paso M- Maximization - actualizar parámetros: π_k, μ_k, Σ_k

Final: Iterar entre pasos E y M: Detener cuando los parámetros dejan de variar.
Convergencia.

Responsabilidad

Las **responsabilidades** (a menudo denotadas con la letra griega gamma o **r**).
Que tan probable es que un punto haya sido generado por un clúster determinado.
Es una medida local (específica para un dato individual X_i).

NO confundir con el peso **π** que es una medida global para todo el dataset).

Imagina un análisis con 3 clústeres de clientes: **Jóvenes**, **Adultos** y **Adultos Mayores**.

- **Pesos (π_k):** Sabes de antemano que el dataset general tiene un 50% de Jóvenes ($\pi_1 = 0.50$), 30% de Adultos ($\pi_2 = 0.30$) y 20% de Adultos Mayores ($\pi_3 = 0.20$). **Estos valores no cambian cliente por cliente.**
- **Responsabilidad ($\gamma_{i,k}$):** Llega el cliente **Carlos** (X_i, con 22 años). El modelo calcula cuánto encaja Carlos en cada grupo combinando su edad con los pesos globales:
  - Responsabilidad del clúster Jóvenes: $\gamma_{\text{Carlos},1} = 0.92$ (92%)
  - Responsabilidad del clúster Adultos: $\gamma_{\text{Carlos},2} = 0.07$ (7%)
  - Responsabilidad del clúster Mayores: $\gamma_{\text{Carlos},3} = 0.01$ (1%)

Expectation-Maximization (EM)

Paso 0- Inicialización: K-means para obtener los valores iniciales de π_k, μ_k, Σ_k

Paso E- Expectation -
Calcular responsabilidades **r_ik,** para cada punto X_i y cada componente K (cluster).

$$\gamma_{ik} = \frac{\pi_k N(x_i|\mu_k, \sigma_k)}{\sum_j \pi_j N(x_i|\mu_j, \sigma_j)}$$

Paso M- Maximization - actualizar: π_k, μ_k, Σ_k

$$\mu_1^{nuevo} = \frac{\sum_i \gamma_{i1} x_i}{\sum_i \gamma_{i1}}$$

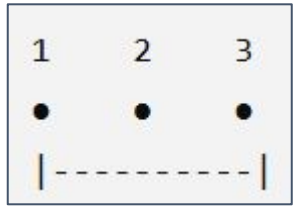
$$\sigma_1^{2,new} = \frac{\sum_i \gamma_{i1}(x_i - \mu_1^{new})^2}{\sum_i \gamma_{i1}}$$

$$\pi_k^{new} = \frac{\sum_i \gamma_{ik}}{N}$$

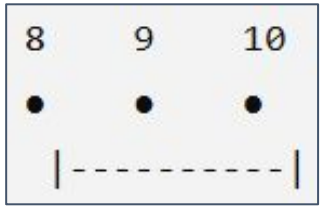
Final: Convergencia al iterar entre pasos E-M.

Ejemplo:
Tenemos un dataset $X = [1, 2, 3, 8, 9, 10]$

Decimos a GMM:
Queremos 2 clusters.
k=2



Cluster 1



Cluster 2

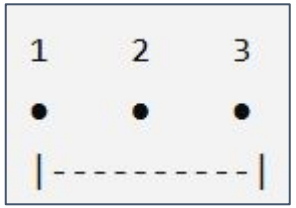
GMM va a intentar encontrar dos distribuciones gaussianas: **G1** y **G2**.
Cada una tiene: media **μ**, una varianza **σ2**, peso **π**.

Paso 0- Inicialización de media **μ**, una varianza **σ2**, peso **π.**
Opción 1 (por defecto): Corre K-means sobre los datos para obtener media **μ** y varianza **σ2**.
El valor de la responsabilidad es r_ik=1 para el cluster asignado.

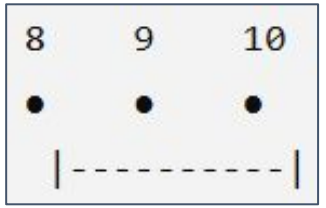
Opción 2: K-means++ usa solo la parte de inicialización inteligente de K-means (elegir centros iniciales bien separados) sin correr las iteraciones completas de K-means. Es más rápido que la opción 1.

Opción 3: random valores de responsabilidades al azar y de ahí se calcula media **μ** y varianza **σ2**.

$$X = [1, 2, 3, 8, 9, 10]$$



Cluster 1



Cluster 2

GMM va a intentar encontrar dos distribuciones gaussianas: **G1** y **G2**.

Paso 0- Inicialización:

$$\mu_1 = 4 \qquad \mu_2 = 7$$

$$\sigma_1 = \sigma_2 = 3$$

$$\pi_1 = \pi_2 = 0.5$$

Estas gaussianas inicialmente están bastante mal ubicadas.

Paso E- Expectation: Calcular responsabilidades para cada punto

¿Qué tan probable es que este punto haya sido generado por G1?
¿Qué tan probable es que este punto haya sido generado por G2?

$$X = [1, 2, 3, 8, 9, 10]$$

Calculemos para X_i= X_1= 2

$$\gamma_{ik} = \frac{\pi_k N(x_i|\mu_k, \sigma_k)}{\sum_j \pi_j N(x_i|\mu_j, \sigma_j)} \longrightarrow N(x|\mu, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Calcular probabilidad que el punto X_1=2 haya sido generado por G1?

$$N(2|4, 3) \longrightarrow \frac{1}{3\sqrt{2\pi}} e^{-\frac{(2-4)^2}{18}} \longrightarrow \frac{1}{7.52} e^{-4/18} \longrightarrow 0.106$$

Calcular probabilidad que el punto X_1=2 haya sido generado por G2?

$$N(2|7, 3) \longrightarrow \frac{1}{3\sqrt{2\pi}} e^{-\frac{(2-7)^2}{18}} \longrightarrow \frac{1}{7.52} e^{-25/18} \longrightarrow 0.033$$

Calculemos para X_1=2

$$\pi_1 = \pi_2 = 0.5$$

$$\gamma_{ik} = \frac{\pi_k N(x_i|\mu_k, \sigma_k)}{\sum_j \pi_j N(x_i|\mu_j, \sigma_j)}$$

$$N(2|4,3) \rightarrow 0.106$$

$$N(2|7,3) \rightarrow 0.033$$

Calcular probabilidad que el punto X_1=2 haya sido generado por G1?

$$\gamma_{11} = \frac{0.5(0.106)}{0.5(0.106) + 0.5(0.033)} \approx 0.76 \rightarrow P(G_1|x=2) \approx 76\%$$

Calcular probabilidad que el punto X_1=2 haya sido generado por G2?

$$\gamma_{12} = \frac{0.5(0.033)}{0.5(0.106) + 0.5(0.033)} \approx 0.2374 \rightarrow P(G_2|x=2) \approx 24\%$$

$$X = [1, 2, 3, 8, 9, 10]$$

Con las gaussianas actuales, considero que X_i=2 tiene un 76% de responsabilidad con G1 y 24% con G2.
Ahora calculo las responsabilidades para todos los puntos.

Punto	G1	G2
1	0.83	0.17
2	0.76	0.24
3	0.68	0.32
8	0.32	0.68
9	0.24	0.76
10	0.17	0.83

Paso M- Maximization: Actualizar valores

¿Donde deberían estar las nuevas gaussianas?

Calcular la nueva media de G1:

$$\mu_1^{nuevo} = \frac{\sum_i \gamma_{i1} x_i}{\sum_i \gamma_{i1}}$$

$$\mu_1^{nuevo} = \frac{10.81}{3.00}$$

$$\mu_1^{nuevo} \approx 3.60$$

$$\sum_i \gamma_{i1} = 3.00$$

x	Responsabilidad G1
1	0.17
2	0.24
3	0.32
8	0.68
9	0.76
10	0.83

$$\sum_i \gamma_{i1} x_i = 10.81$$

$$1(0.17) = 0.17$$

$$2(0.24) = 0.48$$

$$3(0.32) = 0.96$$

$$8(0.68) = 5.44$$

$$9(0.76) = 6.84$$

$$10(0.83) = 8.30$$

Paso M- Maximization: Actualizar valores

¿Donde deberían estar las nuevas gaussianas?

Calcular la nueva media de G2:

$$\mu_2^{nuevo} = \frac{\sum_i \gamma_{i2} x_i}{\sum_i \gamma_{i2}}$$

$$\mu_2^{nuevo} = \frac{22.19}{3}$$

$$\mu_2^{nuevo} \approx 7.40$$

$$\sum_i \gamma_{i1} = 3.00$$

x	Responsabilidad G2
1	0.83
2	0.76
3	0.68
8	0.32
9	0.24
10	0.17

$$\sum_i \gamma_{i1} x_i = 22.19$$

$$1(0.83) = 0.83$$

$$2(0.76) = 1.52$$

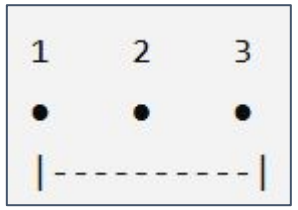
$$3(0.68) = 2.04$$

$$8(0.32) = 2.56$$

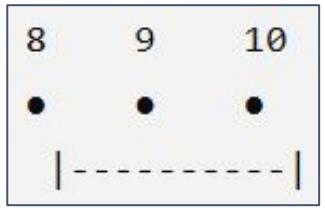
$$9(0.24) = 2.16$$

$$10(0.17) = 1.70$$

$$X = [1, 2, 3, 8, 9, 10]$$

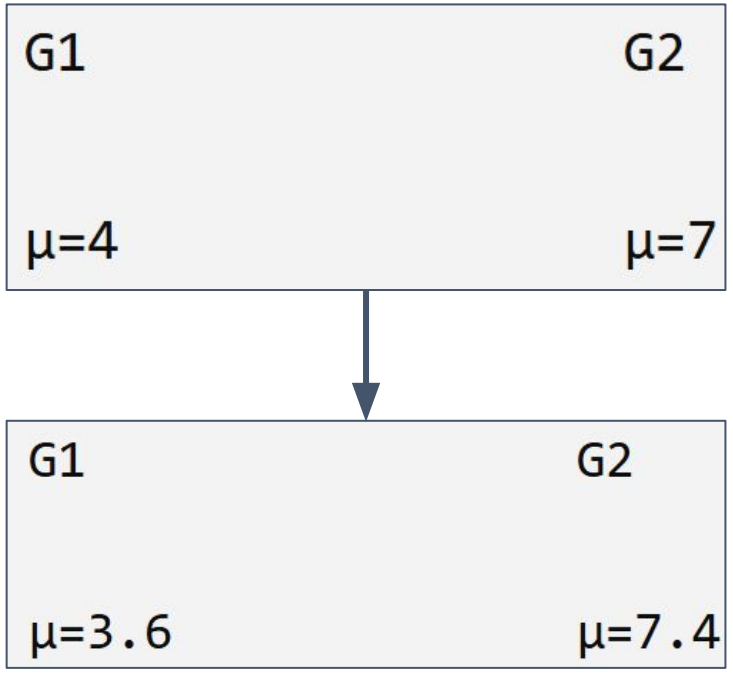


Cluster 1



Cluster 2

Inicialmente teníamos:



Después del M-step:

Paso M- Maximization: Actualizar valores

¿Donde deberían estar las nuevas gaussianas?

$$X = [1, 2, 3, 8, 9, 10]$$

x	Responsabilidad G1
1	0.17
2	0.24
3	0.32
8	0.68
9	0.76
10	0.83

Calcular la nueva varianza de G1:

$$\sigma_1^{2,new} = \frac{\sum_i \gamma_{i1}(x_i - \mu_1^{new})^2}{\sum_i \gamma_{i1}}$$

$$\mu_1^{nuevo} \approx 3.60$$

$$\sum_i \gamma_{i1} = 3$$

$$\sum_i \gamma_{i1}(x_i - \mu_1^{new})^2 = 27.958$$

$$\begin{aligned} 0.83\,(1 - 3.6)^2 &= 5.6108 \\ 0.76\,(2 - 3.6)^2 &= 1.9456 \\ 0.68\,(3 - 3.6)^2 &= 0.2448 \\ &\vdots \\ 0.17\,(10 - 3.6)^2 &= 6.9632 \end{aligned}$$

$$\sigma_1^2 = \frac{27.958}{3} \approx 9.32$$

$$\sigma_1 \approx 3.05$$

$$X = [1, 2, 3, 8, 9, 10]$$

x	Responsabilidad G2
1	0.83
2	0.76
3	0.68
8	0.32
9	0.24
10	0.17

Paso M- Maximization: Actualizar valores

¿Donde deberían estar las nuevas gaussianas?

Calcular la nueva varianza de G2:

$$\sigma_2^{2,new} = \frac{\sum_i \gamma_{i2}(x_i - \mu_2^{new})^2}{\sum_i \gamma_{i2}}$$

$$\sum_i \gamma_{i2}(x_i - \mu_2^{nuevo})^2 = \mathbf{27.958}$$

$$\mu_2^{nuevo} \approx 7.04$$

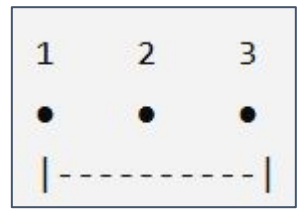
$$\sum_i \gamma_{i1} = 3$$

$$0.17\,(1 - 7.04)^2 = 6.9632$$
$$0.24\,(2 - 7.04)^2 = 6.9984$$
$$0.32\,(3 - 7.04)^2 = 6.1952$$
$$\vdots$$
$$0.83\,(10 - 7.04)^2 = 5.6108$$

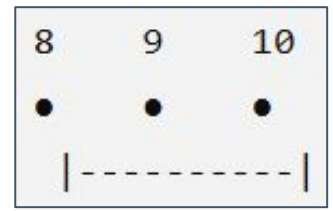
$$\sigma_2^2 = \frac{27.958}{3} \approx 9.32$$

$$\sigma_2 \approx 3.05$$

$$X = [1, 2, 3, 8, 9, 10]$$



Cluster 1



Cluster 2

Inicialmente teníamos:

G1	G2
μ=4	μ=7
σ≈3.00	σ≈3.00

Después de la 1ª iteración (después del M-step):

G1	G2
μ=3.6	μ=7.4
σ≈3.05	σ≈3.05

Paso M- Maximization: Actualizar valores

¿Qué proporción de los datos pertenece a G1?

$$X = [1, 2, 3, 8, 9, 10]$$

x	Responsabilidad G1
1	0.17
2	0.24
3	0.32
8	0.68
9	0.76
10	0.83

Calcular el nuevo peso π para G1:

$$\pi_1^{new} = \frac{\sum_i \gamma_{i1}}{N}$$

$$\sum_i \gamma_{i1} = 3$$

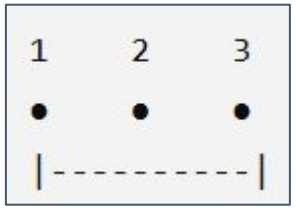
$N = 6$ (número total de datos)

$$\pi_1^{new} = \frac{3.00}{6} = 0.50$$

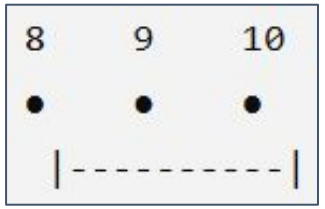
$$\pi_1^{new} \approx 0.50$$

Interpretación: El 50% de los datos pertenece a G1 (según las responsabilidades actuales).

$$X = [1, 2, 3, 8, 9, 10]$$



Cluster 1



Cluster 2

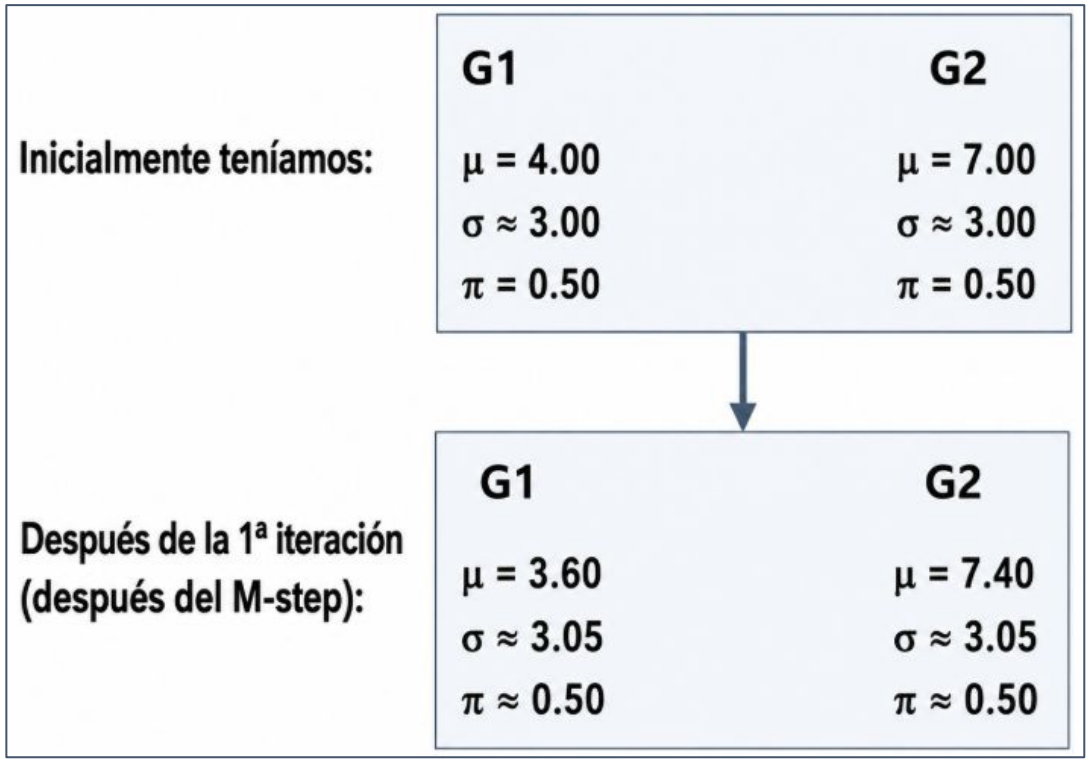
Inicialmente teníamos:

G1	G2
μ = 4.00	μ = 7.00
σ ≈ 3.00	σ ≈ 3.00
π = 0.50	π = 0.50

Después de la 1ª iteración (después del M-step):

G1	G2
μ = 3.60	μ = 7.40
σ ≈ 3.05	σ ≈ 3.05
π ≈ 0.50	π ≈ 0.50

Los pesos **π** indican la proporción de los datos asignada a cada gaussiana.



Ya tenemos nuevas gaussianas.
Entonces volvemos a calcular responsabilidades.
Y luego actualizar los **μ**, **σ**, **π**...

Realizar esta iteración hasta converger.

$$\Delta\mu \approx 0 \qquad \Delta\sigma \approx 0 \qquad \Delta\pi \approx 0$$

```
miGMM = GaussianMixture(n_components=3,random_state=42, covariance_type="spherical")
```

Tipos de matriz de covarianza (`covariance_type`)

Tipo	Forma de los clusters
`spherical`	Círculos/esferas, un solo radio por cluster
`diag`	Elipses alineadas a los ejes (sin rotación)
`tied`	Misma forma y orientación para todos los clusters
`full`	Elipses de cualquier tamaño, forma y rotación (la más flexible)

```
miGMM = GaussianMixture(n_components=3,random_state=42,n_init=1)
```

n_init=1

El algoritmo de Expectación-Maximización (EM) que utiliza `GaussianMixture` es muy sensible a la posición inicial de los clústeres.

Si la inicialización es mala, el modelo puede quedar atrapado en un **mínimo local** (una solución subóptima).

Valor por defecto: **n_init**=1.

Costo computacional: Cada ejecución adicional multiplica el tiempo total de entrenamiento (por ejemplo, con n_init=10, el proceso tardará aproximadamente 10 veces más).

Practica 7

Muchas Gracias